IMPLEMENTASI MASK R-CNN UNTUK MENDETEKSI AREA DI UNIVERSITAS LAMPUNG DALAM TATA KELOLA LAHAN

(Skripsi)

Oleh

MUHAMMAD BAYU TIAR
2117051071

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS LAMPUNG
BANDAR LAMPUNG
2026

IMPLEMENTASI MASK R-CNN UNTUK MENDETEKSI AREA DI UNIVERSITAS LAMPUNG DALAM TATA KELOLA LAHAN

Oleh

MUHAMMAD BAYU TIAR

Skripsi

Sebagai Salah Satu Syarat untuk Mencapai Gelar
SARJANA ILMU KOMPUTER

Pada

Jurusan Ilmu Komputer
Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Lampung

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS LAMPUNG
BANDAR LAMPUNG
2026

ABSTRAK

IMPLEMENTASI MASK R-CNN UNTUK MENDETEKSI AREA DI UNIVERSITAS LAMPUNG DALAM TATA KELOLA LAHAN

Oleh

MUHAMMAD BAYU TIAR

Implementasi teknologi computer vision berbasis deep learning dalam pemetaan area bangunan menjadi salah satu solusi strategis untuk mendukung tata kelola lahan yang lebih efisien. Penelitian ini mengimplementasikan metode Mask Region-Based Convolutional Neural Network (Mask R-CNN) dengan backbone ResNet-50 Feature Pyramid Network (FPN) untuk mendeteksi, men-segmentasi, dan memperkirakan luas bangunan fakultas di Universitas Lampung menggunakan citra udara drone. Dataset yang digunakan terdiri dari 594 citra hasil frame capturing video drone dengan total 5.369 objek bangunan yang dianotasi dalam format COCO JSON. Data dibagi menjadi 70% training, 20% validation, dan 10% testing. Proses pelatihan dilakukan menggunakan transfer learning dengan optimizer AdamW, mekanisme early stopping, serta evaluasi menggunakan COCOeval. Kinerja segmentasi dievaluasi menggunakan metrik mAP, AP50, AP75, dan IoU, sedangkan estimasi luas bangunan dievaluasi menggunakan MAE, MAPE, dan WAPE setelah dilakukan konversi skala dari piksel persegi (px^2) ke meter persegi (m^2) berdasarkan median rasio per kelas. Hasil pengujian menunjukkan bahwa model mencapai mAP sebesar 82,03%, AP50 sebesar 94,52%, AP75 sebesar 89,50%, serta rata-rata IoU sebesar 88,12%. Pada tahap estimasi luas, diperoleh MAE rata-rata sebesar 8,063 m^2, MAPE sebesar 4,205%, dan WAPE sebesar 3,579%. Hasil tersebut menunjukkan bahwa Mask R-CNN mampu melakukan segmentasi bangunan secara presisi serta memberikan estimasi luas area yang akurat dan konsisten. Dengan demikian, pendekatan ini berpotensi mendukung pemetaan detail kampus dan perencanaan tata kelola lahan berbasis citra drone secara lebih efektif.

Kata Kunci: Mask R-CNN, segmentasi instance, citra drone, deteksi bangunan, estimasi luas area, deep learning, computer vision, COCOeval, tata kelola lahan.

ABSTRACT

IMPLEMENTATION OF MASK R-CNN TO DETECT AREAS AT THE UNIVERSITY OF LAMPUNG IN LAND GOVERNANCE

By

MUHAMMAD BAYU TIAR

The implementation of deep learning–based computer vision technology for building area mapping has become a strategic solution to support more efficient land management. This study implements the Mask Region-Based Convolutional Neural Network (Mask R-CNN) method with a ResNet-50 Feature Pyramid Network (FPN) backbone to detect, segment, and estimate the area of faculty buildings at Universitas Lampung using drone aerial imagery. The dataset consists of 594 images extracted from drone video frames, containing a total of 5,369 annotated building objects in COCO JSON format. The data were divided into 70% training, 20% validation, and 10% testing sets. The training process employed transfer learning with the AdamW optimizer, an early stopping mechanism, and evaluation using COCOeval. Segmentation performance was evaluated using mAP, AP50, AP75, and IoU metrics, while building area estimation was assessed using MAE, MAPE, and WAPE after applying a scale conversion from square pixels (px^2) to square meters (m^2) based on the median ratio per class. The experimental results indicate that the model achieved an mAP of 82.03%, AP50 of 94.52%, AP75 of 89.50%, and a mean IoU of 88.12%. In the area estimation stage, the model obtained an average MAE of 8.063 m^2, a MAPE of 4.205%, and a WAPE of 3.579%. These findings demonstrate that Mask R-CNN is capable of performing precise building segmentation while providing accurate and consistent area estimation. Therefore, this approach has strong potential to support detailed campus mapping and drone-based land management planning more effectively.

Keywords: Mask R-CNN, instance segmentation, drone imagery, building detection, area estimation, deep learning, computer vision, COCOeval, land management.

Judul Skripsi	:	**IMPLEMENTASI MASK R-CNN UNTUK MENDETEKSI AREA DI UNIVERSITAS LAMPUNG DALAM TATA KELOLA LAHAN**
Nama Mahasiswa	:	Muhammad Bayu Tiar
Nomor Pokok Mahasiswa	:	2117051053
Program Studi	:	Ilmu Komputer
Fakultas	:	Matematika dan Ilmu Pengetahuan Alam

MENYETUJUI

Komisi Pembimbing

Dr. rer. nat. Akmal Junaidi, M.Sc. NIP. 19710129 199702 1 001	**Ridho Sholehurrohman, M. Mat** NIP. 232111970128101

MENGETAHUI

Ketua Jurusan Ilmu Komputer	Ketua Program Studi S1 Ilmu Komputer
Dwi Sakethi, S.Si., M.Kom. NIP. 19680611 199802 1 001	**Tristiyanto, M.I.S., Ph.D.** NIP. 19810414 200501 1 0001

MENGESAHKAN

1. Tim Penguji

Ketua	: **Dr. rer. nat. Akmal Junaidi, M.Sc.**	……
Sekretaris	: **Ridho Sholehurrohman, M.Mat**	……
Penguji Utama	: **Prof. Admi Syarif, Ph.D**	……

2. Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam

Dr. Eng. Heri Satria, S.Si., M.Si.
NIP. 19711001 200501 1 002

Tanggal Lulus Ujian Skripsi: **28 Januari 2026**

PERNYATAAN

Saya yang bertanda tangan di bawah ini:

Nama : Muhammad Bayu Tiar

NPM : 2117051071

Dengan ini menyatakan bahwa skripsi saya yang berjudul "Implementasi Mask R-CNN untuk Mendeteksi Area di Universitas Lampung dalam Tata Kelola Lahan" adalah benar hasil karya tulis saya sendiri dan bukan karya orang lain. Seluruh isi dan penulisan yang tertuang dalam skripsi ini telah disusun sesuai dengan kaidah penulisan karya ilmiah yang berlaku di Universitas Lampung. Apabila di kemudian hari terbukti bahwa skripsi ini merupakan hasil penjiplakan atau dibuat oleh pihak lain, maka saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku.

Bandar Lampung, 24 Februari 2026
Penulis,

Muhammad Bayu Tiar
NPM. 2117051071

RIWAYAT HIDUP

Penulis dilahirkan di Natar pada 03 April 2002 sebagai anak pertama dari dua bersaudara dari pasangan Bapak Ivan Bayu Syahputra dan Ibu Sugiarti. Penulis menyelesaikan pendidikan Sekolah Dasar (SD) di SD Negeri 5 Merak Batin Natar pada Tahun 2014, kemudian melanjutkan pendidikan Sekolah Menengah Pertama (SMP) di SMP Yadika Natar dan lulus pada Tahun 2017, serta menyelesaikan pendidikan Sekolah Menengah Atas (SMA) di SMA Negeri 1 Natar pada Tahun 2020. Pada Tahun 2021, penulis terdaftar sebagai mahasiswa Program Studi S1 Ilmu Komputer Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Lampung melalui jalur Seleksi Bersama Masuk Perguruan Tinggi Negeri (SBMPTN).

Selama menjadi mahasiswa, penulis melakukan beberapa kegiatan antara lain:

1. Menjadi Anggota Media Informasi Himpunan Mahasiswa Ilmu Komputer (HIMAKOM) Universitas Lampung pada periode 2022–2023.
2. Melaksanakan Kerja Praktik (KP) di Badan Narkotika Nasional Provinsi Lampung pada Tahun 2024.
3. Melaksanakan Kuliah Kerja Nyata (KKN) Periode II Universitas Lampung di Desa Pasir Sakti, Lampung Timur pada Tahun 2024.

MOTTO

"Better late than never but never late is better."
(Drake)

"Never let success get to your head, and never let failure get to your heart."
(Drake)

"Stand on your decision, finish what you start, and never quit."
(Author)

"when writing the story of your life never let anyone else hold the pen."
(Author)

PERSEMBAHAN

Alhamdulillahirabbil ‘alamin, puji dan syukur penulis panjatkan ke hadirat Allah SWT atas rahmat, karunia, serta pertolongan-Nya yang tiada henti, sehingga penulis dapat melalui setiap proses, tantangan dan rintangan hingga akhirnya dapat menyelesaikan skripsi ini. Segala hikmah, kesehatan dan kekuatan yang diberikan menjadi sumber semangat bagi penulis untuk terus berusaha dan bertahan sampai pada tahap ini.

Skripsi ini saya persembahkan kepada:

Kepada kedua orang tua tercinta Bapak Ivan Bayu Syahputra dan Ibu Sugiarti, serta saudara tercinta, yang senantiasa memberikan doa, kasih sayang, dukungan moral maupun materi serta menjadi motivasi terbesar dalam setiap perjalanan hidup penulis. Segala pengorbanan, kesabaran dan cinta yang tulus menjadi landasan utama bagi penulis untuk terus berusaha dan memberikan yang terbaik. Penulis juga mempersembahkan karya ini kepada seluruh teman-teman Angkatan 2021 Program Studi Ilmu Komputer Universitas Lampung yang telah bersama-sama melalui proses perkuliahan, berbagi pengalaman serta memberikan semangat dan dukungan selama perjalanan akademik.

SANWACANA

Puji dan syukur penulis panjatkan ke hadirat Allah SWT atas rahmat, karunia, dan pertolongan-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul *"Implementasi Mask R-CNN untuk Mendeteksi Area di Universitas Lampung dalam Tata Kelola Lahan"*. Skripsi ini dapat terselesaikan berkat doa, dukungan, bimbingan, serta bantuan dari berbagai pihak yang telah memberikan kontribusi secara langsung maupun tidak langsung. Oleh karena itu, pada kesempatan ini penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Kedua orang tua tercinta yang selalu menjadi sumber kekuatan dan inspirasi. Ayah yang tak pernah berhenti mengajarkan arti perjuangan dan kerja keras, serta Ibu yang senantiasa menjadi tempat pulang penuh cinta, doa, dan keteduhan. Tanpa doa dan kasih kalian, langkah ini tidak akan pernah berarti.
2. Bapak Dr. Eng. Heri Satria, S.Si., M.Si. selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Lampung.
3. Bapak Dwi Sakethi, S.Si., M.Kom. selaku Ketua Jurusan Ilmu Komputer Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Lampung.
4. Bapak Tristiyato, M.I.S., Ph.D. selaku Ketua Program Studi S1 Ilmu Komputer Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Lampung.
5. Ibu Yunda Heningtyas, M.Kom. selaku Sekeretaris Jurusan Ilmu Komputer Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Lampung.
6. Favorisen R. Lumbanraja S.Kom., M.Si., Ph.D selaku dosen Pembimbing Akademik, yang telah memberikan arahan, motivasi, serta nasihat selama penulis menempuh studi akhir di Jurusan Ilmu Komputer.
7. Bapak Dr. rer. nat. Akmal Junaidi, M.Sc, selaku dosen Pembimbing Utama yang dengan penuh kesabaran telah memberikan arahan, masukan, serta bimbingan hingga skripsi ini dapat terselesaikan dengan baik.

8. Ridho Sholehurrohman, M.Mat, selaku dosen Pembimbing Kedua yang telah memberikan bantuan, masukan, dan saran berharga yang membuat skripsi ini dapat diselesaikan dengan baik.
9. Prof. Admi Syarif, Ph.D selaku dosen Pembahas Utama yang telah meluangkan waktu, memberikan arahan serta memberikan banyak masukan dan motivasi yang bermanfaat dalam kehidupan maupun proses penyusunan skripsi ini.
10. Bapak dan Ibu Dosen Jurusan Ilmu Komputer FMIPA Universitas Lampung, atas segala ilmu, bimbingan serta pengalaman berharga yang telah diberikan kepada penulis selama masa perkuliahan.
11. Ibu Ade Nora Maela selaku staf administrasi Jurusan Ilmu Komputer FMIPA Universitas Lampung yang telah banyak memberikan bantuan dan kemudahan dalam proses administrasi sehingga penulis dapat menyelesaikan skripsi ini dengan lancar.
12. Seluruh staf Jurusan Ilmu Komputer FMIPA Universitas Lampung atas segala bantuan dan kerjasama yang telah memudahkan penulis selama menempuh studi.
13. Adik tersayang, Aura Bayu Agakra, yang selalu menjadi alasan untuk bersemangat sehingga penulis dapat menyelesaikan skripsi ini dengan baik.
14. Rekan-rekan Ilmu Komputer Angkatan 2021, atas persahabatan, perjuangan serta kebersamaan yang telah menjadi bagian berharga dalam perjalanan studi penulis.
15. Untuk teman-teman saya, khususnya khususnya Hanif, Ibe, Nopal El, Elvis yang telah menemani dalam melakukan bimbingan serta memberikan dukungan dalam proses penulisan skripsi dan juga dimasa-masa akhir studi.
16. Seluruh keluarga besar Ucup yang tidak bisa disebutkan satu per satu, atas doa, semangat dan dukungan yang senantiasa mengiringi langkah penulis hingga skripsi ini selesai.

17. Kepada Micelle Yap Aswin atas dukungan, kesabaran, dan ketulusan yang senantiasa diberikan kepada penulis selama proses perkuliahan hingga penyusunan skripsi ini. Kehadiran, doa, serta keyakinan yang diberikan menjadi sumber ketenangan dan kekuatan bagi penulis dalam menghadapi berbagai tantangan akademik, sehingga penelitian ini dapat diselesaikan dengan baik.
18. Kepada Drake, yang melalui karya musik dan lirik-liriknya secara tidak langsung memberikan motivasi dan menemani penulis dalam berbagai sesi pengerjaan skripsi hingga penelitian ini dapat diselesaikan.
19. Teruntuk diri sendiri, yang telah mempertahankan setiap keputusan, menuntaskan setiap proses yang dimulai, dan memilih untuk tidak menyerah dalam menghadapi berbagai rintangan hingga skripsi ini dapat diselesaikan.

Penulis menyadari bahwa dalam penyusunan skripsi ini masih terdapat banyak kekurangan, baik dari segi isi maupun penyajian, yang disebabkan oleh keterbatasan pengalaman dan pengetahuan penulis. Oleh karena itu, kritik, saran, dan masukan yang membangun dari para pembaca sangat penulis harapkan, agar dapat menjadi pembelajaran dan bahan perbaikan di masa yang akan datang.

Bandar Lampung, 24 Februari 2026

Muhammad Bayu Tiar
NPM. 2117051071

I. DAFTAR ISI

DAFTAR ISI ..... **i**
DAFTAR GAMBAR ..... **iv**
DAFTAR TABEL ..... **vi**
DAFTAR KODE ..... **vii**

I. PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Batasan Masalah 2
1.4 Tujuan Penelitian 3
1.5 Manfaat Penelitian 3

II. TINJAUAN PUSTAKA **5**
2.1 Penelitian – Penelitian Terkait 5
2.2 Pengolahan Citra Digital 7
2.3 Video Digital 7
2.4 Citra Udara Drone 8
2.5 Skala 8
2.6 Deteksi Objek 9
2.7 *Computer Vision* 9
2.8 *Artificial Intelligence* (AI) 9
2.9 *Machine Learning* (ML) 10
2.10 *Deep Learning* 10
2.11 *Convolution Neural Network* (CNN) 10
2.11.1 *Convolution Layer* 11
2.11.2 *Pooling Layer* 11
2.11.3 *Fully Connected Layer* 12

2.12 *Region-Based Convolutional Neural Network* (R-CNN) 12
2.13 *Region Proposal Network* (RPN) 12
2.14 *Region of Interest* (RoI) 12
2.15 *Fully Convolutional Network* (FCN) 13
2.16 *Mask Region-Based Convolutional Neural Network* (Mask R-CNN) 13
2.17 *Intersection over Union* (IoU) 14
2.18 *Average Precision* (AP) 16
2.19 *Mean Average Precision* (mAP) 16
2.20 *Common Objects in Context* (COCO) JSON 17
2.21 COCOEval 17
2.22 *Mean Absolute Error* (MAE) 17
2.23 *Mean Absolute Percentage Error* (MAPE) 18
2.24 *Weighted Absolute Percentage Error* (WAPE) 18

III. METODE PENELITIAN 19
3.1 Waktu dan Tempat Penelitian 19
3.2 Perangkat Penelitian 19
3.2.1 Alat Penelitian 19
3.2.2 Bahan Penelitian 20
3.3 Tahapan Penelitian 21
3.3.1 Pengumpulan Data 22
3.3.2 *Pre-Processing* 22
3.3.3 Pembagian Dataset 23
3.3.4 *Training* Model Mask R-CNN 23
3.3.5 Evaluasi Metode Mask R-CNN 24
3.3.6 Analisis Hasil 24

IV. HASIL PENELITIAN DAN PEMBAHASAN 25
4.1 Dataset Penelitian 25
4.2 *Pre-processing* 27
4.2.1 *Frame Capturing* 27
4.2.2 *Resize* 28
4.2.3 Anotasi Data 28

4.3 Pembagian Dataset 29
4.4 *Training* Model 30
4.5 *Testing* Model 44
4.5.1 Analisis Hasil Deteksi dan Segmentasi 44
4.6 Evaluasi Model 47
4.6.1 Evaluasi Hasil Deteksi Objek 48
4.6.2 Evaluasi Hasil AP dan mAP 52
4.6.3 Penerapan Faktor Skala ($px^2 \rightarrow m^2$) 56
4.6.4 Evaluasi Prediksi Luas Area 61
4.7 Analisis Hasil 64

V. SIMPULAN DAN SARAN 66
5.1 Simpulan 66
5.2 Saran 67

DAFTAR PUSTAKA

II. DAFTAR GAMBAR

Gambar 1. Pengolahan Citra Digital (Ahlul Halliwa, 2023) 7
Gambar 2. Hasil Citra Udara Drone (Saihu et al., 2023) 8
Gambar 3. Keterkaitan antara AI, ML, dan Deep Learning 9
Gambar 4. Arsitektur CNN (Tammina, 2019) 10
Gambar 5. Ilustrasi Convolution Layer (Tammina, 2019) 11
Gambar 6. Ilustrasi Pooling Layer (Tammina, 2019) 11
Gambar 7. Arsitektur Mask R-CNN (Wulan Dari & Triloka, 2022) 14
Gambar 8. *Ground-truth* dan *Predicted Bounding Box* (Rosebrock, 2022) 14
Gambar 9. Ilustrasi Perhitungan IoU (Rosebrock, 2022) 15
Gambar 10. Flowchart Tahapan Penelitian 21
Gambar 11. Ilustrasi penerbangan drone 26
Gambar 12. Ilustrasi pengambilan drone dari ketinggian 27
Gambar 13. Sampel *frame image* 28
Gambar 14. Proses anotasi data 29
Gambar 15. Ilustrasi pembagian dataset di Roboflow 29
Gambar 16. Visualisasi *feature map* dari *backbone* ResNet-50 32
Gambar 17. Visualisasi *multi-scale feature map* dari FPN (P2, P3, P4, P5) 33
Gambar 18. Hasil *RoIAlign* untuk enam RoI pertama 34
Gambar 19. Visualisasi keluaran *detection head* 34
Gambar 20. Grafik *training loss* dan validasi metrik AP50 38
Gambar 21. Grafik *training error* dan validasi *error* AP50 39
Gambar 22. Grafik *training loss* dan validasi metrik AP75 40
Gambar 23. Grafik *training error* dan validasi *error* AP75 41
Gambar 24. Grafik *training loss* dan validasi metrik mAP 42
Gambar 25. Grafik *training error* dan validasi *error* mAP 42
Gambar 26. Hasil *testing* model Mask R-CNN 45

Gambar 27. Visualisasi *mask ground truth* dan *mask* prediksi 48
Gambar 28. Visualisasi *bounding box box prediction* dan *GT bounding box* 49
Gambar 29. Grafik rata-rata nilai IoU per-kelas 51
Gambar 30. Hasil evaluasi AP50 per-kelas 52
Gambar 31. Hasil evaluasi AP75 per-kelas 54
Gambar 32. Hasil evaluasi mAP per-kelas 55
Gambar 33. Hasil segmentasi *mask* 58
Gambar 34. Distribusi faktor skala ($px^2 \rightarrow m^2$) per kelas bangunan 59
Gambar 35. Grafik hasil evaluasi kinerja model Mask R-CNN 64

III. DAFTAR TABEL

Tabel 1. Penelitian-Penelitian Terkait 5
Tabel 2. Waktu Penelitian 19
Tabel 3. Nilai Hyperparameter Tuning Mask R-CNN 31
Tabel 4. Nilai terbaik performa model Mask R-CNN validasi selama training dan pada pengujian 43
Tabel 5. data luas aktual dan prediksi 55
Tabel 6. Hasil statistik kesalahan prediksi luas berdasarkan metrik MAE, MAPE, dan WAPE. 55

IV. DAFTAR KODE

Kode Program 1. Struktur utama model Mask R-CNN 35
Kode Program 2. *Training loop* model Mask R-CNN 36
Kode Program 3. Validasi *COCOeval*, *checkpoint*, dan *early stopping* 37
Kode Program 4. Perhitungan rasio faktor skala ($px^2 \rightarrow m^2$)..... 51

I. PENDAHULUAN

1.1. Latar Belakang

Universitas Lampung (UNILA) merupakan perguruan tinggi negeri di Provinsi Lampung yang terletak di Kecamatan Rajabasa. UNILA memiliki delapan fakultas yang setiap tahunnya terus melakukan pembangunan gedung maupun pemanfaatan tata kelola lahan. Seiring perkembangan teknologi digital yang semakin pesat, UNILA perlu memanfaatkan teknologi cerdas untuk mendukung pemetaan, analisis rancangan pembangunan, serta perencanaan tata kelola lahan secara lebih efisien. Salah satu pendekatan yang relevan adalah *Computer Vision*, yaitu kemampuan komputer dalam mengenali dan memahami gambar atau video (Ardian, Zakaria, & Susilo, 2016).

Computer Vision merupakan sub-bidang *Artificial Intelligence* (AI) dan *Deep Learning* yang berfokus pada bagaimana komputer dapat melihat dan menafsirkan dunia di sekitarnya (Marpaung, Aulia, & Nabila, 2022). Perkembangan signifikan dalam bidang ini terlihat dari kemajuan pada pengolahan citra digital, di mana gambar dapat diproses untuk mengekstrak informasi penting guna mendukung pengambilan keputusan. Salah satu metode *Deep Learning* yang saat ini banyak digunakan untuk pemrosesan citra adalah Mask R-CNN.

Mask R-CNN (*Mask Region-Based Convolutional Neural Network*) merupakan pengembangan dari Faster R-CNN yang tidak hanya mampu mendeteksi objek, tetapi juga menghasilkan segmentasi *mas*k secara piksel demi piksel (Ariya & Lina, 2023). Dengan memanfaatkan *RoIAlign*, Mask R-CNN mampu menjaga keselarasan antara *input* dan *output* sehingga meningkatkan akurasi segmentasi hingga 50% dibandingkan metode sebelumnya (He, Gkioxari, & Girshick, 2017).

Dalam konteks kebutuhan pemetaan dan monitoring di lingkungan kampus, penggunaan *Unmanned Aerial Vehicle* (UAV) atau drone menjadi alternatif yang efektif dibandingkan metode manual maupun citra satelit. Drone dapat menghasilkan citra udara dengan resolusi tinggi secara fleksibel tanpa terhambat kondisi cuaca atau keterbatasan waktu (Saihu, Purba, & Sarkowi, 2023). Integrasi antara teknologi drone dan Mask R-CNN berpotensi memberikan hasil pemetaan yang lebih akurat dan detail, sekaligus mendukung analisis spasial dalam tata kelola lahan.

Beberapa penelitian terdahulu menunjukkan keberhasilan Mask R-CNN dalam meningkatkan akurasi deteksi dan segmentasi objek (He et al., 2017; Chen et al., 2020; Hou & Li, 2024). Namun, penerapannya pada citra drone untuk mendeteksi area kampus, khususnya dalam konteks Universitas Lampung, masih sangat terbatas. Oleh karena itu, penelitian yang berjudul "Implementasi Mask R-CNN untuk Mendeteksi Area di Universitas Lampung" ini berfokus pada implementasi Mask R-CNN untuk mendeteksi area kampus Universitas Lampung dari citra drone. Tujuannya adalah untuk menghasilkan sistem yang tidak hanya mampu mendeteksi dan men-segmentasi bangunan fakultas, tetapi juga memperkirakan luas area bangunan secara kuantitatif, sehingga dapat dimanfaatkan dalam perencanaan pembangunan, tata kelola lahan, dan mendukung inisiatif *Green Metric* kampus.

1.2. Rumusan Masalah

Adapun rumusan masalah dari penelitian ini adalah sebagai berikut:

1. Bagaimana implementasi *Mask R-CNN* untuk mendeteksi area di Universitas Lampung?
2. Bagaimana performansi metode *Mask R-CNN* dalam mendeteksi objek area menggunakan citra udara drone?
3. Bagaimana akurasi model Mask R-CNN dalam memperkirakan luas area bangunan (m^2) dari hasil segmentasi citra drone?

1.3. Batasan Masalah

Adapun batasan masalah dari penelitian ini adalah sebagai berikut:

1. Penelitian dibatasi pada lingkungan Universitas Lampung dan tidak mencakup area di luar kampus.
2. Data citra diperoleh menggunakan drone (UAV) dengan ketinggian tertentu, sehingga kualitas hasil dipengaruhi oleh faktor resolusi kamera, kondisi cuaca, dan sudut pengambilan gambar.
3. Objek yang dideteksi terbatas pada bangunan gedung fakultas (objek statis) menggunakan metode segmentasi instance Mask R-CNN. Objek dinamis seperti kendaraan atau manusia tidak termasuk dalam lingkup penelitian.
4. Penelitian hanya mencakup 3 fakultas (FKIP, FMIPA, dan FK) dengan pertimbangan ketersediaan data citra drone serta keterbatasan waktu penelitian. Oleh karena itu, hasil penelitian belum mewakili seluruh area kampus.
5. Sumber pembanding SDGS UNILA dalam pembangunan berkelanjutan dan *Green Metric* mengenai lingkungan hijau.

1.4. Tujuan

Adapun tujuan dari penelitian ini adalah sebagai berikut:

1. Mengimplementasikan Mask R-CNN untuk mendeteksi area di lingkungan Universitas Lampung.
2. Mengevaluasi akurasi dan efisiensi Mask R-CNN dalam mendeteksi dan melakukan segmentasi *instance* objek pada citra yang diperoleh dari area di Universitas Lampung.

1.5. Manfaat

Adapun manfaat dari penelitian ini adalah sebagai berikut:

1. Mendukung pengelolaan fasilitas kampus dengan menyediakan informasi spasial berbasis citra drone, sehingga area gedung fakultas dapat terdeteksi dan dipetakan secara lebih akurat.
2. Meningkatkan penerapan teknologi kecerdasan buatan (AI) dalam manajemen lingkungan pendidikan, khususnya melalui deteksi objek dan segmentasi citra untuk keperluan tata kelola lahan dan perencanaan pembangunan kampus.

3. Menjadi acuan bagi penelitian lanjutan yang ingin mengembangkan metode deteksi dan segmentasi berbasis Mask R-CNN maupun model *deep learning* lainnya dalam konteks pengolahan citra udara.
4. Dapat digunakan sebagai bahan perencaann *Green Metric* Universitas Lampung dalam upaya mewujudkan kampus hijau yang berkelanjutan yang berfokus pada kelestarian lingkungan.

II. TINJAUAN PUSTAKA

2.1 Penelitian – Penelitian Terkait

Tabel 1. Penelitian-Penelitian Terkait.

No	Penulis	Judul Paper	Objek	Pokok Bahasan
1.	(He,K., Gkioxari, G., Dollár, P.,& Girshick, R., 2017).	Mask R-CNN	Pendeteksian dan segmentasi *instance* objek dalam gambar.	Penelitian ini membahas mengenai algoritma Mask R-CNN yang merupakan pengembangan dari algoritma Faster R-CNN. Mask R-CNN memperbaiki kekurangan pada Faster R-CNN dibagian keselarasan segmentasi dengan mengganti metode *RoIPooling* dengan metode *RoIAlign* yang mampu meningkatkan akurasi prediksi mask hingga 10%-50%. Mask R-CNN menunjukan hasil *instance segmentation* dengan *mask AP* sebesar 35,7 dan *bounding box AP* sebesar 38,2.

2.	(Chen, J., Wang, G., Luo, L., Gong, W. & Cheng, Z. 2021).	*Building Area Estimation in Drone Aerial Images Based on Mask R-CNN*	Bangunan yang teridentifikasi pada citra udara drone	Penelitian ini membahas penggunaan Mask R-CNN untuk memperkirakan luas area bangunan menggunakan citra udara dari drone pada area pedesaan yang rawan bencana. Berdasarkan hasil penelitian ini, Mask R-CNN mencapai F1 *Score* sebesar 0.875 dan IoU sebesar 0.769.
3.	Hou, T. dan Li, J. (2024)	*Application of mask R-CNN for building detection in UAV remote sensing images*	bangunan perkotaan dan pedesaan	Penelitian ini membahas penerapan Mask R-CNN untuk meningkatkan akurasi deteksi dan ekstraksi fitur gedung dari citra UAV. Berdasarkan hasil penelitian ini Mask R-CNN menunjukan kinerja dengan tingkat akurasi klasifikasi mencapai 95% dan akurasi koreksi *frame* hingga 88,67% serta berhasil mengurangi tingkat kesalahan deteksi dengan *False Negative Rate* (FNR) serendah 4,5%.

2.2 Pengolahan Citra Digital

Pengolahan citra digital merupakan ilmu yang mempelajari tentang hal-hal yang berkaitan dengan perbaikan kualitas terhadap suatu gambar (meningkatkan kontras, perubahan warna, restorasi citra), transformasi gambar (translasi, rotasi transformasi, skala, geometrik), melakukan pemilihan citra ciri (feature images) yang optimal untuk tujuan analisis, melakukan penyimpanan data yang sebelumnya dilakukan reduksi dan kompresi, transmisi data, dan waktu proses data (Aqdi, 2023). Berikut adalah gambaran sederhana dari proses pengolahan citra digital:

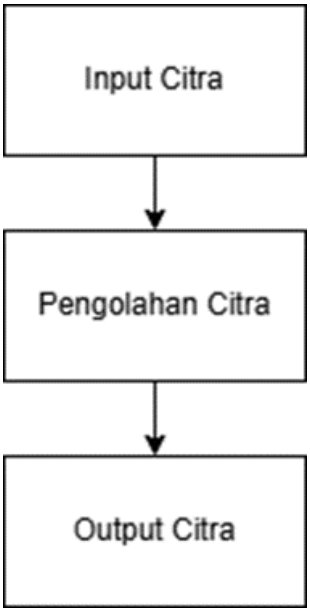

Gambar 1. Pengolahan Citra Digital (Aqdi, 2023).

2.3 Video Digital

Video digital merupakan representasi informasi melalui sekumpulan citra yang digabungkan dan ditampilkan sesuai dengan standar *scanning system*, *frame rate*, dan *frame size* yang digunakan oleh teknologi video tersebut. Video digital tidak hanya digunakan sebagai media penyimpanan atau pengarsipan informasi tetapi juga digunakan sebagai media pertukaran informasi (Wardhani & Madenda, 2016).

2.4 Citra Udara (Drone)

Teknologi drone saat ini berkembang dengan pesat dan telah banyak dimanfaatkan dalam berbagai kegiatan dan bidang keilmuan. Drone merupakan pesawat tanpa awak yang dikendalikan dari jarak jauh oleh *auto pilot*. Penggunaan drone bukan hanya untuk mengambil gambar foto udara dan video, namun juga dapat digunakan dalam proses pengindaraan jarak jauh, monitoring tata ruang kontruksi bangunan, dan juga pemetaan lahan (Saihu et al., 2023). Berikut merupakan citra udara yang dihasilkan dengan drone:

Gambar 2. Hasil Citra Udara Drone (Saihu et al., 2023).

2.5 Skala

Konversi luas dari piksel persegi (px^2) ke meter persegi (m^2) dilakukan untuk menerjemahkan hasil segmentasi citra ke ukuran spasial yang sesuai dengan kondisi lapangan. Setiap piksel memiliki representasi ukuran tertentu sesuai resolusi citra, sehingga luas objek dalam piksel perlu dikalibrasi menggunakan faktor skala yang dihitung dari perbandingan antara luas anotasi dan luas aktual. Pendekatan ini banyak digunakan dalam pemetaan dan ekstraksi bangunan berbasis citra, karena hubungan spasial antar-piksel dapat diubah menjadi geometri objek yang dapat diukur secara akurat setelah proses segmentasi (Emelyanov et al., 2024). Adapun perhitungan skala dihitung menggunakan persamaan berikut:

$$Skala = \frac{Luas\ Aktual\ (m^2)}{Luas\ Anotasi\ (px^2)} \tag{1}$$

2.6 Deteksi Objek

Deteksi objek adalah pendekatan dalam *machine learning* yang berfokus pada identifikasi dan lokalisasi berbagai objek dalam gambar dan video. Setiap objek memiliki fitur atau karakteristik tersendiri yang membantu membedakannya dalam frame foto atau video. Selain mendeteksi fitur, mesin juga melakukan pencocokan fitur atau features matching (Marpaung et al., 2022). Deteksi objek merupakan teknologi komputer yang berhubungan dengan citra digital dan pengolahan citra yang digunakan untuk melakukan pendeteksian sebuah objek seperti gedung, manusia, atau benda (Ariya & Lina, 2023).

2.7 Computer Vision

Computer vision merupakan sub-bidang dari *Artificial Intelligence* yang memungkinkan komputer untuk memahami dan menganalisis gambar atau video layaknya cara manusia melihat. *Computer vision* adalah integrasi dari proses akusisi citra, pengolahan citra, pengenalan dan pembuat keputusan yang digunakan untuk meniru cara kerja sistem visual manusia yang dapat mengenali objek objek tertentu (Putra & Antony, 2018).

2.8 *Artificial Intelligence (AI)*

Kecerdasan buatan (*Artificial Intelligence* atau AI) merupakan cabang dari ilmu komputer yang berfokus pada pengembangan sistem yang mampu meniru kemampuan berpikir dan bertindak seperti manusia (Nawawi et al., 2024). Melalui AI, komputer dapat belajar dari pengalaman, mengenali pola, mengambil keputusan, serta menyelesaikan tugas-tugas kompleks secara otomatis dan efisien. Teknologi AI mencakup berbagai pendekatan dan subbidang, di antaranya *machine learning* yang memungkinkan sistem belajar dari data tanpa pemrograman eksplisit, serta *deep learning* yang memanfaatkan arsitektur jaringan saraf tiruan berlapis untuk memproses dan mengekstraksi informasi dari data berskala besar (Janiesch et al., 2021).

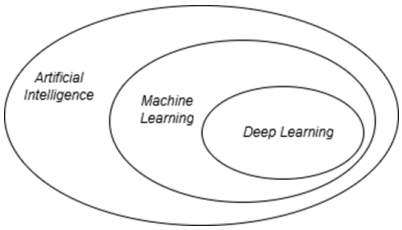

Gambar 3. Keterkaitan antara AI, ML dan Deep Learning.

2.9 Machine Learning (ML)

Machine Learning atau pembelajaran mesin, cabang dari AI-kecerdasan buatan, merupakan disiplin ilmu yang mencakup perancangan dan pengembangan algoritma yang digunakan untuk mengembangkan mesin otomatis berdasakan eksekusi pada algoritma dan kumpulan aturan yang terdefinisi. Oleh karena itu dapat dikategorikan sebagai intruksi yang dijalankan secara otomatis untuk mengubah data menjadi beberapa pola dan diinputkan jauh ke dalam sistem untuk mendekteri masalah otomatis serta mendapatkan output yang optimal (Raup et al., 2022).

2.10 Deep Learning

Deep Learning mulai banyak digunakan sejak tahun 2006 yang menggunakan mekanisme *deep architecture of learning. Learning* atau pembelajaran dalam ini merupakan sebuah prosedur proses estimasi parameter suatu model yang dikembangkan (algoritma) dapat menyelesaikan tugas atau permasalahan tertentu. *Deep Learning* merupakan sebuah teknik berbasis jaringan saraf tiruan telah banyak digunakan sebagai salah satu metode implementasi dalam *Machine Learning* (Diponegoro et al., 2021).

2.11 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah jenis jaringan saraf buatan yang dirancang khusus untuk menganalisis gambar. Salah satu keunggulan CNN adalah kemampuannya memanfaatkan hubungan lokal pada gambar, sehingga bisa menggunakan lebih sedikit parameter karena beberapa di antaranya digunakan bersama. Hal ini membuat CNN lebih efisien dalam penggunaan memori dan komputasi (Tammina, 2019). Metode ini terdiri atas tiga lapisan seperti pada gambar berikut:

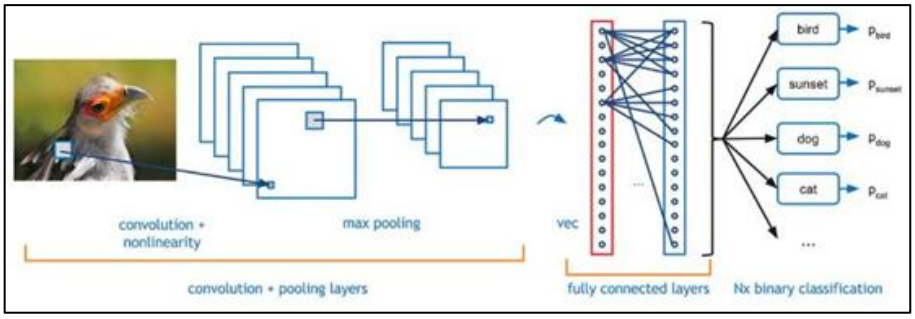

Gambar 4. Arsitektur CNN (Tammina, 2019).

2.11.1 Convolution Layer

Convolution layer adalah komponen utama dalam jaringan saraf konvolusi (CNN) yang digunakan untuk mengekstraksi fitur penting dari data dalam pemerosesan citra. Proses ini melibatkan penggunaan filter atau kernel yang digeser di seluruh data input untuk menghasilkan peta fitur (*feature map*). Pada setiap posisi, kernel melakukan operasi perkalian elemen dengan data input dan menjumlahkan hasilnya. Operasi ini dikenal sebagai konvolusi, yang berfungsi untuk menangkap pola lokal seperti tepi, tekstur, atau struktur tertentu. Lapisan konvolusi banyak digunakan di berbagai bidang, termasuk pengolahan citra, statistik, dan fisika, karena kemampuannya dalam menyederhanakan data kompleks sambil mempertahankan informasi penting (Tammina, 2019).

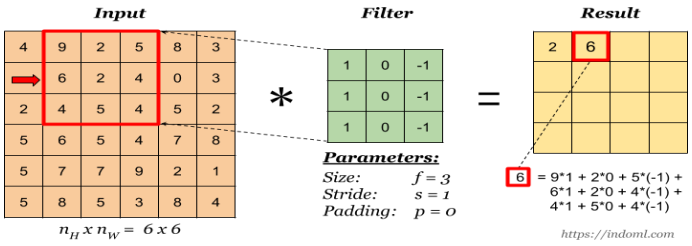

Gambar 5. Ilustrasi *Convolution Layer* (Tammina, 2019).

2.11.2 Pooling Layer

pada prinsipnya *pooling layer* terdiri dari filter dengan ukuran tertentu yang akan memperbesar seluruh area *feature map*. Terdapat dua jenis *pooling* yang biasa digunakan yaitu *max pooling* yang merupakan penyatuan maksimum pada setiap *shift* filter akan memilih nilai terbesar dan *average pooling* yang merupakan penyatuan rata-rata akan memilih nilai rata-rata. Tujuan utama dari *pooling layer* adalah untuk memperkecil ukuran *feature map* (*downsampling*) sehingga dapat mempercepat proses komputasi dan mengontrol terjadinya *overfitting* (Prastowo, 2021).

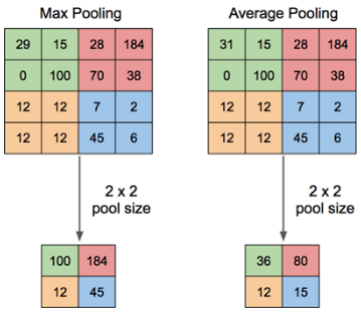

Gambar 6. Ilustrasi *Pooling Layer* (Tammina, 2019)

2.11.3 Fully Connected Layer

Fully Connected Layer (FCL) adalah bagian penting dalam jaringan syaraf tiruan yang berfungsi menghubungkan semua neuron dari satu lapisan ke lapisan berikutnya. Biasanya, lapisan ini berada di bagian akhir jaringan, setelah proses konvolusi dan *pooling* selesai mengambil fitur-fitur penting dari data, misalnya gambar. Peran utama FCL adalah menggabungkan fitur-fitur tersebut menjadi informasi yang dapat digunakan untuk membuat keputusan, seperti mengklasifikasikan atau memprediksi (BJ, Nugroho, Maharani, & Saifullah, 2023).

2.12 Region-Based Convolutional Neural Network (R-CNN)

Region-Based Convolutional Neural Network (R-CNN) merupakan algoritma *Convolutional Neural Network* (CNN) yang dirancang khusus untuk deteksi dan klasifikasi objek dalam gambar. R-CNN bekerja dengan cara memetakan area tertentu dalam gambar yang kemungkinan besar mengandung objek yang ingin dikenali, kemudian melakukan klasifikasi pada area tersebut (Fitriani, 2021).

2.13 Region Proposal Network (RPN)

Region Proposal Network (RPN) merupakan algoritma deteksi objek yang menjadi bagian dari keluarga CNN seperti RCNN, Faster CNN, maupun Mask R-CNN. Dalam prosesnya algoritma ini digunakan untuk pencarian lokasi-lokasi objek dari suatu gambar dengan cepat. Posisi dari objek-objek yang sesuai dengan pencarian akan diberi batas dan ditandai sebagai *Region of Interest* (RoI). Algoritma RPN akan mengambil sub-citra yang sudah ditandai dengan berbagai ukuran objek sebagai input yang diteruskan ke dalam jaringan CNN (BJ, Nugroho, Maharani, & Saifullah, 2023).

2.14 Region of Interest (RoI)

Region of Interest (RoI) adalah teknik yang memungkinkan pemrosesan citra terfokus hanya pada wilayah atau area yang dianggap penting, tanpa harus memproses keseluruhan gambar. Pendekatan ini memberikan beberapa manfaat, seperti mengurangi waktu komputasi, mengoptimalkan penyimpanan data, dan memfasilitasi pengambilan keputusan yang lebih akurat dengan memusatkan perhatian pada bagian citra yang

relevan. RoI bekerja dalam pengkodean area tertentu dari citra digital secara berbeda, sehingga area penting akan memiliki kualitas yang lebih baik dibandingkan area sekitarnya (Pratomo et al., 2020).

2.15 Fully Convolutional Network (FCN)

Fully Convolutional Neural Network (FCN) merupakan pengembangan dari CNN dimana semua *layer* yang digunakan hanyalah *convolutional layer*. Dibandingkan menggunakan *fully-connected layer* seperti pada CNN dalam prediksi, FCN tetap menggunakan *convolutional layer* untuk mengklasifikasi data ke dalam kelas-kelas. Tujuan utama dari FCN adalah menghasilkan segmentasi semantik, dimana *output* memiliki ukuran yang sama dengan gambar *input* dan menyerupai gambar aslinya. *Output* FCN sendiri melakukan prediksi pada *pixel-pixel* pada citra (Nirmalasari, 2020).

2.16 Mask Region-Based Convolutional Neural Network (Mask R-CNN)

Mask Regional Convolutional Neural Network (Mask R-CNN) adalah jaringan saraf dalam yang bertujuan untuk menyelesaikan masalah segmentasi *instance* dalam pembelajaran mesin atau *computer vision*. *Mask R-CNN* merupakan sebuah *framework* untuk melakukan segmentasi objek yang merupakan perkembangan dari metode sebelumnya, yaitu *Faster R-CNN*. Metode ini menambahkan fitur yang mampu melakukan prediksi terhadap dimana kemungkinan sebuah objek berada dan memberikan mask atau lapisan pada objek. Pada *Mask R-CNN*, diciptakan sebuah layer baru untuk memprediksi *segmentation mask* dari tiap *Region of Interest* (ROI) yang berjalan secara paralel dengan *layer* untuk klasifikasi dan *bounding box regression* yang sudah ada sebelumnya (He et al., 2017).

Mask R-CNN memberikan tiga keluaran untuk setiap objek kandidat, yaitu label kelas, objek pembatas, dan objek topeng (*mask*). Hal tersebut tentunya membuat algoritma deteksi objek dari Mask R-CNN lebih baik karena tedapat variabel tambahan yaitu objek topeng yang tentunya membuat deteksi dari objek yang diinginkan lebih baik. Mask R-CNN juga memiliki beberapa kelebihan diantaranya mudah untuk dilatih, mengungguli semua entri model tunggal yang ada pada setiap tugas, sangat efisien dan hanya menambahkan sedikit tugas diatas Faster R-CNN, dan yang terakhir Mask R-CNN mudah di generalisasi ke tugas yang lain (Ayudhawara et al., 2023).

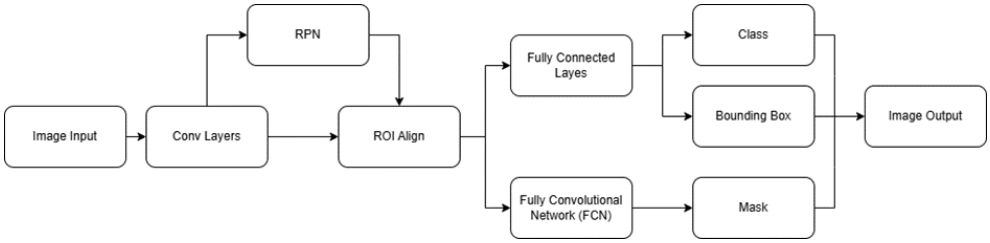

Gambar 7. Arsitektur Mask R-CNN (Wulan Dari & Triloka, 2022).

Berdasarkan gambar 7 dapat dilihat bahwa *instance segmentation* mirip dengan *object detection* di mana masing-masing objek dideteksi satu per satu namun kemudian dikombinasikan dengan *semantic segmentation* sehingga setiap objek dapat diketahui kelas, lokasi serta dapat dibedakan pikselnya. Dalam melakukan deteksi, Mask R-CNN dapat dibagi menjadi tiga bagian, yaitu: *feature extraction network*, *region-proposal network*, dan *instance detection and segmentation networks* (Shi et al., 2019). Mask R-CNN memakai seluruh gambar sebagai input CNN untuk ekstraksi fitur, kemudian *Region Proposal Network* (RPN) mengkeluarankan RoI sebagai *region* yang diusulkan dari suatu gambar. Setelah itu Mask R-CNN menggabungkan keluaran ekstraksi fitur gambar dengan *region* yang diusulkan, lalu memperhitungan kategori, kotak pembatas, dan memberi mask pada objek.

2.17 Intersection over Union (IoU)

Intersection over Union adalah salah satu metrik evaluasi yang umum digunakan dalam bidang *Computer Vision*, khususnya dalam tugas segmentasi gambar dan deteksi objek. IoU dapat digunakan untuk mengukur seberapa baik sebuah model dapat memprediksi lokasi atau segmentasi objek pada gambar dengan membandingkan hasil prediksi model dengan nilai *ground truth* atau nilai yang sebenarnya (Budi et al., 2023).

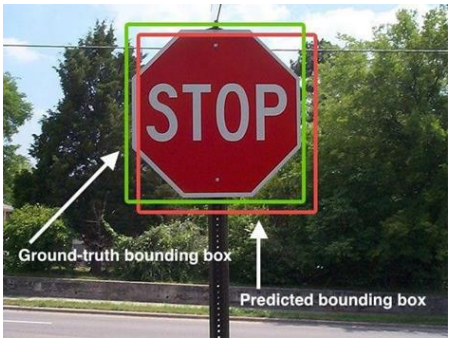

Gambar 8. *Ground-truth dan Predicted bounding box* (Rosebrock, 2022).

Berdasarkan gambar 8 dapat dilihat bahwa pendeteksi objek telah mendeteksi gambar rambu lalu lintas. Kotak merah adalah predicted *bounding box* sedangkan kotak berwarna hijau adalah ground-truth *bounding box*. Predicted *bounding box* adalah *bounding box* yang diprediksi oleh algoritma. Sedangkan ground-truth *bounding box* adalah *bounding box* yang berasal dari dataset yang sudah diberi label (Darmanto et al., 2023). Dengan kedua bounding box tersebut perhitungan IoU dapat dilihat pada persamaan (1) sebagai berikut:

$$IoU = \frac{|A \cap B|}{|A \cup B|} \tag{2}$$

Keterangan:

$A = Bounding\ box\ ground\ thrut.$
$B = Bounding\ box\ prediction.$
$C = \ Bounding\ box\ terkecil\ yang\ mencakup\ A\ dan\ B.$

Gambar 9 berikut merupakan ilustrasi perhitungan IoU.

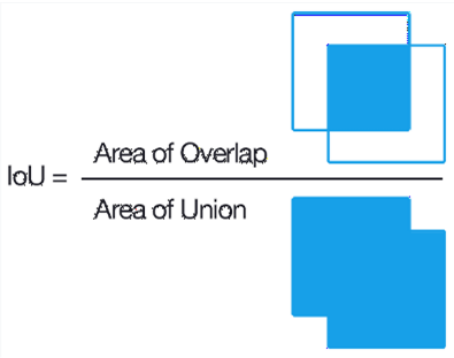

Gambar 9. Ilustrasi Perhitungan IoU (Rosebrock, 2022).

Dari gambar 9 dapat diartikan bahwa IoU adalah hasil pembagian dari *area of overlap* dan *area of union*. *Area of overlap* adalah irisan dari *ground- truth bounding box* dan *predicted bounding box*. *Area of union* adalah gabungan dari *ground-truth bounding box* dan *predicted bounding box*. Rentang IoU adalah 0 sampai 1, semakin mendekati 1 semakin baik kesesuaian prediksi dengan *ground truth* (Darmanto et al., 2023).

2.18 Average Precision (AP)

Average Precision adalah metrik yang digunakan untuk mengukur kinerja model deteksi objek berdasarkan *Precision* dan *Recall* (PR). AP membandingkan ketepatan prediksi dari keseluruhan data yang diterima dengan data yang sebenarnya. *Precision* adalah proporsi dari hasil prediksi positif dengan jawaban yang *real positive*. Sedangkan recall adalah kebalikan dari *precision*, yaitu proporsi *real positive* yang terprediksi positif (Powers, 2020). Perhitungan *precision* dan *recall* diperoleh dari rumus berikut:

$$precision = \frac{True\ Positive}{True\ Positive + False\ Positive}$$

$$recall = \frac{True\ Positive}{True\ Positive + False\ Negative} \tag{3}$$

True Positive adalah ketika model berhasil melakukan deteksi objek dan hasil prediksi sesuai dengan label, *False Positive* adalah ketika model berhasil melakukan deteksi objek namun hasil prediksi berbeda dengan label, *False Negative* adalah model tidak dapat mendeteksi objek sama sekali (Powers, 2020). Dari hasil perhitungan kedua nilai tersebut maka akan dilanjutkan untuk menghitung nilai AP *(Average Precision)* dengan cara menghitung rata-rata nilai *precision* dari keseluruhan *recall*. Perhitungan AP dapat dilihat pada rumus berikut:

$$AP = \frac{1}{11}\sum_{Recall_i - 11} Precesion(Recall_i) \tag{4}$$

2.19 Mean Average Precision (mAP)

Mean Average Precision (mAP) merupakan metrik utama yang digunakan dalam evaluasi model deteksi objek. mAP dihitug sebagai rata-rata dari nilai AP untuk semua kelas dalam dataset (Pradana, 2024). Perhitungan mAP dilakukan dengan merata-ratakan AP untuk setiap kelas, yang dirumuskan sebagai berikut:

$$\mathrm{mAP} = \frac{1}{\mathrm{N}}\sum_{\mathrm{i=N}}^{\mathrm{N}} \mathrm{AP_i} \tag{5}$$

2.20 Common Objects in Context (COCO) JSON

COCO JSON adalah format anotasi yang dipakai untuk menyimpan informasi objek dalam bentuk file JSON yang terstruktur, seperti posisi bounding box, kategori objek, dan detail anotasi lainnya. Format ini memudahkan proses pelabelan dan pemrosesan data karena strukturnya jelas serta mudah dibaca oleh model deep learning. Dalam jurnal Gemelli et al. (2024), format COCO JSON dijelaskan sebagai skema anotasi yang umum digunakan dan bahkan dapat diperluas (*augmented*) sesuai kebutuhan. Penggunaan format ini membantu menjaga konsistensi anotasi dan membuat data lebih kompatibel dengan berbagai model deteksi modern (Gemelli et al., 2024).

2.21 COCOEval

COCOeval adalah modul evaluasi resmi pada *COCO* API yang digunakan untuk mengukur performa sistem deteksi objek secara lebih ketat dibandingkan standar PASCAL VOC. Evaluasi dilakukan dengan menghitung AP dan mAP pada rentang nilai IoU 0,50–0,95 dengan *interval* 0,05, sehingga penilaian tidak hanya bergantung pada keberhasilan klasifikasi, tetapi juga ketepatan tumpang-tindih prediksi terhadap ground truth. Pendekatan ini membuat *COCOeval* mampu memberikan evaluasi yang lebih komprehensif, stabil, dan representatif terhadap kualitas model deteksi objek (Padilla et al., 2021).

2.22 Mean Absolute Error (MAE)

Mean Absolute Error (MAE) adalah sebuah metrik evaluasi yang digunakan untuk menilai seberapa baik model statistik atau model *machine learning* sesuai dengan data empiris atau observasi aktual . MAE dihitung sebagai rata-rata dari nilai absolut kesalahan prediksi (tanpa memperhatikan tanda positif atau negatif). Nilai MAE yang lebih rendah menunjukkan performa model yang lebih baik dalam memodelkan data, karena hal ini mengindikasikan bahwa selisih antara prediksi dan nilai aktual cenderung kecil (Tambunan & Nainggolan, 2023). Nilai MAE dapat ditentukan menggunakan rumus pada persamaan (6) berikut ini:

$$MAE = \frac{1}{n}\sum_{i=1}^{n} |y' - y_i| \tag{6}$$

Keterangan:

y' : Nilai hasil prediksi
y : Nilai aktual
n : Jumlah data

2.23 Mean Absolute Percentage Error (MAPE)

Mean Absolute Percentage Error (MAPE) merupakan indikator statistik yang digunakan untuk menilai tingkat akurasi hasil prediksi pada metode peramalan. Metrik ini menghitung rata-rata persentase kesalahan secara absolut antara nilai prediksi dan nilai aktual (Nurani et al., 2023). Metode MAPE dapat dihitung menggunakan rumus pada persamaan (7) berikut ini.

$$MAPE = \frac{1}{n}\sum_{t=1}^{n}\left|\frac{Y_t - Y'_t}{Y_t}\right| \times 100 \tag{7}$$

Keterangan:

$Y_t = nilai\ sebenarnya\ (aktual) ke - t\ (t = 1, \dots, n),$
$Y'_t = nilai\ hasil\ perkiraan\ (prediksi) ke - t\ (t = 1, \dots, n),$
$n = banyaknya\ data\ yang\ diuji.$

2.24 Weighted Absolute Percentage Error (WAPE)

Weighted Absolute Percentage Error (WAPE) merupakan indikator statistik yang digunakan untuk menilai tingkat akurasi hasil prediksi pada metode peramalan. Metrik ini menghitung persentase kesalahan absolut yang ditimbang oleh total nilai aktual; pada data bernilai non-negatif, WAPE dapat dipandang sebagai MAE yang dinormalisasi oleh rata-rata nilai aktual (Annisa et al., 2015). WAPE dapat dihitung menggunakan rumus pada persamaan (8) berikut ini.

$$WAPE = \frac{MAE}{Rata - Rata\ Luas\ Aktual} \times 100 \tag{8}$$

III. METODE PENELITIAN

3.1. Waktu dan Tempat Penelitian

Penelitian ini dilakukan pada Desember 2024 sampai November 2025 yang bertempat pada wilayah Bandar Lampung dan Lab. Komputasi Jurusan Ilmu Komputer, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Lampung dengan jadwal penelitian yang akan ditampilkan pada Tabel 2.

Tabel 2. Waktu Penelitian.

NO	Jadwal Kegiatan	BULAN PELAKSANAAN PENELITIAN 2024/2025											
		Des	Jan	Feb	Mar	Apr	Mei	Jun	Jul	Ags	Sep	Okt	Nov
1.	Penulisan Bab 1-3												
2.	Pengumpulan data												
3.	Seminar Usul												
4.	Pre-Processing Data												
5.	Pembagian Data Training dan Data Testing												
6.	Training Model Mask R-CNN												
7.	Analisis dan evaluasi hasil												
8.	Penulisan Laporan Bab 4-5												
9.	Seminar Hasil Penelitian												

3.2. Perangkat Penelitian

Untuk menunjang penelitian ini dibutuhkan alat dan bahan untuk menyelesaikan beberapa diantaranya:

3.2.1. Alat Penelitian

a. Perangkat Keras

Perangkat keras yang digunakan dalam penelitian ini antara lain:

- Laptop
  - Processor : Intel® Core™ i5-12500H 12th Generation

- RAM : 8 GB
- GPU : NVIDIA® GeForce RTX™ 3050 4 GB Graphics
- Storage : 512 GB SSD Hard drive
- System type : 64-bit operating system, x64- based processor

- Drone

- Sensor Kamera : 1/1.3” CMOS
- Resolusi Foto : 12 MP
- Resolusi Video : 4K/30fps HDR
- Baterai : 2453 mAh
- Navigasi : GPS + GLONASS + Galileo
- Waktu Terbang Max : 38 menit

b. Perangkat Lunak

Perangkat lunak yang digunakan dalam penelitian ini antara lain:

- Sistem operasi Windows 11 Home Single Language 64-bit
- Visual Studio Code versi 1.83.1
- Python versi 3.9.0
- Google Colab
- Google Drive
- Draw.io

3.2.2. Bahan Penelitian

Bahan yang digunakan pada penelitian ini berupa gambar dan video area fakultas Universitas Lampung yang diambil secara langsung menggunakan drone di lingkungan kampus Universitas Lampung.

3.3. Tahapan Penelitian

Desain struktur metodologi penelitian Implementasi Mask R-CNN Untuk Mendeteksi Area di Universitas Lampung Dalam Tata Kelola Lahan yang akan ditunjukan pada gambar 10 sebagai berikut:

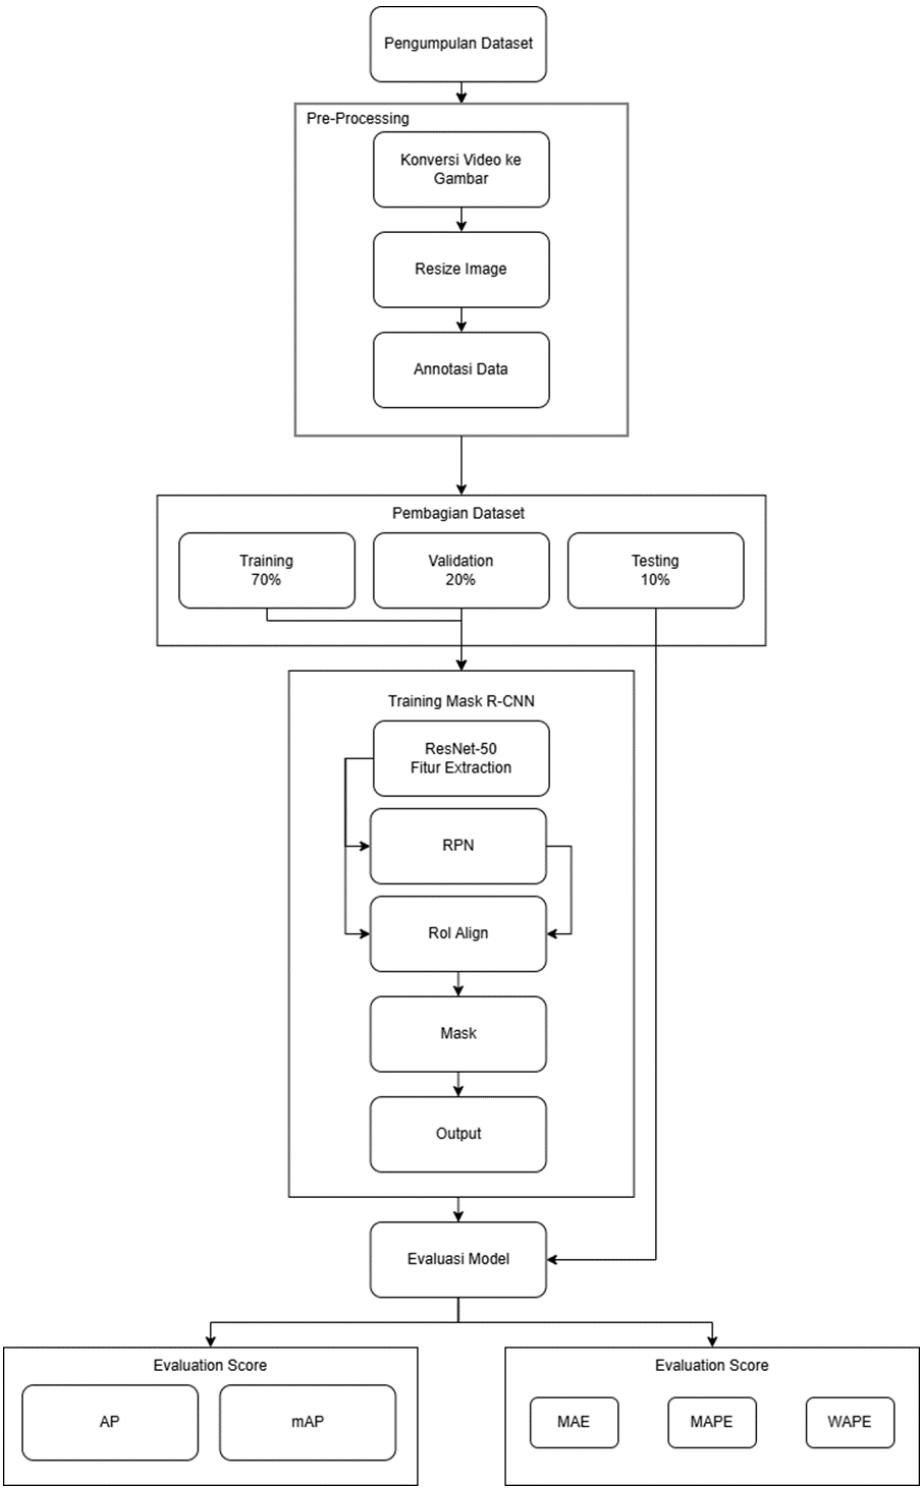

Gambar 10. Flowchart Tahapan Penelitian.

3.3.1. Pengumpulan Data

Dataset yang digunakan pada penelitian ini diperoleh dari hasil rekaman area fakultas di lingkungan Universitas Lampung. Pengambilan data ini dilakukan secara langsung dengan merekam dari udara menggunakan kamera udara (*drone*).

3.3.2. Pre-processing

Pre-processing data dalam penelitian ini merupakan tahap awal dalam pengolahan citra agar siap digunakan untuk melakukan proses *training.* Tahapan ini bertujuan untuk memperbaiki kualitas citra dan mempersiapkan data citra yang digunakan sebagai data input di tahap selanjutnya. *Pre-processing* terdiri dari beberapa tahapan yaitu proses *frame capturing*, *resize* dan anotasi data.

a. *Frame Capturing*

   Dalam melakukan deteksi objek diperlukan data citra sebagai data input. Oleh karena itu, pada tahap ini dilakukan *frame capturing* dari video hasil perekaman drone, di mana video diubah menjadi rangkaian citra (*frame-frame*). Hasil *frame capturing* ini kemudian digunakan untuk proses anotasi sehingga citra dapat dipersiapkan sebagai dataset pada tahap selanjutnya.

b. Proses *Resize*

   Resize adalah langkah untuk mengubah ukuran citra dan berguna untuk memastikan kualitas serta menghasilkan data yang lebih siap untuk ke proses selanjutnya. *Resize* dilakukan untuk menyesuaikan ukuran citra agar memiliki dimensi yang seragam dan memastikan system hanya memproses area yang relevan. Pada penelitian implementasi Mask R-CNN ini semua citra diubah ukuran nya menjadi 854 × 480 piksel agar keseluruhan citra memiliki rasio yang sama.

c. Proses Anotasi Data

   Anotasi adalah pembuatan label pada citra dengan memberikan *bounding box* dan *mask* segmentasi. Untuk melakukan pelatihan model dengan metode *deep learning* berbasis konvolusi, citra perlu dilabeli atau dianotasi. Pada tahap ini, anotasi dilakukan dengan format *COCO JSON* pada setiap karakter gedung di fakultas UNILA.

3.3.3. Pembagian Dataset

Setelah proses anotasi selesai, dataset dibagi menjadi tiga subset menggunakan teknik *simple random sampling* dengan pembagian 70:20:10. Pembagian ini menghasilkan data latih *(training* dataset), data validasi (*validation* dataset), dan data uji (*testing* dataset). Data latih yang berjumlah sekitar 70% digunakan untuk melatih model Mask R-CNN agar dapat mengenali pola dan fitur objek dari citra beranotasi. Data validasi sebesar 20% dimanfaatkan untuk mengevaluasi performa model selama proses pelatihan, sehingga dapat membantu dalam penyesuaian *hyperparameter*, mencegah terjadinya *overfitting*, serta menentukan titik *early stopping* yang optimal. Sementara itu, data uji sebesar 10% berfungsi sebagai data yang sama sekali tidak terlibat dalam proses pelatihan maupun validasi, sehingga mampu memberikan gambaran objektif mengenai performa akhir model terhadap data baru dan mendapatkan evaluasi akhir terhadap performa model.

3.3.4. *Training* Model Mask R-CNN

Tahapan *training* merupakan proses di mana model mempelajari pola dari dataset yang diberikan untuk mengoptimalkan kemampuannya dalam mengklasifikasi dan mengenali karakter pada citra. Pada tahap training model Mask R-CNN, data latih digunakan untuk melatih model, sementara data validasi digunakan untuk mengevaluasi kinerja model secara berkala selama pelatihan.

Model Mask R-CNN dilatih dengan menggunakan ResNet-50 sebagai *backbone* untuk ekstraksi fitur dari gambar area UNILA. Fitur yang diekstraksi ini kemudian dimasukkan ke dalam *Region Proposal Network* (RPN), yang bertugas mengidentifikasi wilayah potensial yang berisi objek (area UNILA). RPN mengusulkan beberapa wilayah yang diidentifikasi sebagai area fakultas, yang kemudian akan diproses lebih lanjut menggunakan RoI (*Region of Interest*) *Align*.

Output dari proses ini adalah prediksi koordinat *bounding box* yang menunjukkan lokasi area UNILA dalam gambar, serta menentukan area tersebut merupakan area UNILA atau bukan. Dalam proses *training* dan akurasi prediksi model dipengaruhi oleh *hyperparameter*. *Hyperparameter* ini adalah parameter yang mengendalikan proses pelatihan model dan memiliki pengaruh besar terhadap kinerja serta akurasi prediksi model.

3.3.5. Evaluasi Metode Mask R-CNN

Langkah selanjutnya adalah melakukan evaluasi untuk mengukur performa model dalam mendeteksi area Universitas Lampung serta menilai akurasi hasil segmentasi dan prediksi luas bangunan. Evaluasi segmentasi dilakukan menggunakan metrik IoU, AP, dan mAP, yang masing-masing digunakan untuk mengukur tingkat tumpang tindih antara hasil prediksi dengan *ground truth* serta ketepatan klasifikasi objek pada berbagai ambang batas IoU. Selain itu, untuk menilai kemampuan model dalam memperkirakan luas area hasil segmentasi, digunakan metrik MAE, MAPE, dan WAPE. MAE digunakan untuk menghitung rata-rata selisih absolut antara luas prediksi dan luas aktual dalam satuan meter persegi, MAPE digunakan untuk mengukur kesalahan relatif dalam bentuk persentase terhadap nilai aktual, sedangkan WAPE menunjukkan proporsi kesalahan absolut terhadap total rata-rata luas sebenarnya. Kombinasi metrik tersebut memberikan gambaran yang komprehensif mengenai kinerja model Mask R-CNN, baik dari sisi ketepatan segmentasi spasial maupun akurasi estimasi luas area bangunan yang dihasilkan.

3.3.6. Analisis Hasil

Pada fase ini, kesimpulan dirumuskan berdasarkan hasil evaluasi kinerja model Mask R-CNN dalam melakukan segmentasi dan memprediksi luas area dibandingkan dengan luas aktual. Tujuan utamanya adalah menentukan sejauh mana model mampu memberikan hasil terbaik dalam hal ketepatan segmentasi serta akurasi prediksi luas.

IV. HASIL PENELITIAN DAN PEMBAHASAN

Penelitian ini mengimplementasikan metode *Mask Region-Based Convolutional Neural Network* (Mask R-CNN) dengan menggunakan ResNet-50 sebagai fitur ekstraktor untuk melakukan deteksi dan segmentasi karakter pada area gedung fakultas UNILA. Pembahasan mencakup seluruh tahapan penelitian, mulai dari pengumpulan dan persiapan dataset hingga evaluasi performa model berdasarkan metrik akurasi.

4.1. Dataset Penelitian

Pada penelitian ini, objek bangunan dikelompokkan ke dalam tiga kategori utama, yaitu FKIP, FMIPA, dan FK, dengan total 48 kelas bangunan. Kategori FKIP terdiri dari 26 kelas (fkip 1 s.d. fkip 26) dengan jumlah 3.311 objek, kategori FMIPA mencakup 14 kelas (fmipa 1 s.d. fmipa 14) dengan 1.742 objek, sedangkan kategori FK terdiri dari 8 kelas (fk 1 s.d. fk 8) dengan 316 objek. Jumlah keseluruhan objek pada dataset adalah 5.369 objek hasil anotasi *polygon* dari citra drone. Pengelompokan ini dilakukan agar setiap bangunan dapat diidentifikasi secara spesifik sesuai fakultasnya, sehingga mendukung proses pelabelan yang konsisten serta meningkatkan akurasi model pada tahap pelatihan dan evaluasi segmentasi.

Pengambilan data dilakukan secara langsung menggunakan kamera drone di lingkungan kampus Universitas Lampung (UNILA). Proses pengambilan gambar dilakukan dengan memperhatikan area yang sesuai kriteria untuk memastikan kualitas dan konsistensi dataset. Berikut adalah rincian kriteria pengambilan data yang diterapkan.

1. Pengambilan data dilakukan pada setiap area fakultas UNILA dilakukan pukul jam 10 sampai dengan jam 12 WIB dimulai pada hari senin sampai selasa. Pemilihan waktu ini agar mendapatkan cahaya yang optimal agar hasil dari rekaman area fakultas dapat terlihat dengan jelas.

2. Data yang diambil berformat MP4 karena merupakan format video yang umum digunakan, memiliki tingkat kompresi yang efisien tanpa mengorbankan kualitas visual secara signifikan, serta kompatibel dengan berbagai perangkat lunak pengolahan video dan Machine Learning

3. Resolusi video adalah 1920×1080 piksel berdurasi 3 menit dengan 30fps

4. Jumlah data yang digunakan dalam penelitian ini adalah sebanyak 594 citra hasil *frame capturing* dari hasil video area fakultas yang direkam menggunakan drone. *Frame* dipilih dengan menerapkan *frame skip* berdasarkan target fps yang lebih rendah dari fps asli video.

5. Proses penggambilan data dilakukan dengan menggunakan kamera drone DJI mini 3 Yang memiliki spesifikasi yang cukup bagus untuk melakukan perekaman dari udara.

Gambar 11. Ilustrasi penerbangan drone.

6. Pada proses pengambilan video, drone diterbangkan pada ketinggian sekitar 10–15 meter dan posisi kamera diarahkan ke bawah dengan sudut miring sekitar 20–25° sehingga menghasilkan kualitas citra area fakultas UNILA yang optimal untuk mendukung proses anotasi dan pemrosesan lebih lanjut.

Gambar 12. Ilustrasi pengambilan citra drone dari ketinggian.

7. Citra yang telah diambil kemudian melalui tahap *preprocessing* untuk mempersiapkan dataset yang akan digunakan dalam melakukan deteksi

4.2. Pre-processing

Penelitian ini melibatkan beberapa tahapan *pre-processing* data yang akan diimplementasikan untuk mempersiapkan dataset.

4.2.1. Frame Capturing

Video hasil perekaman berdurasi sekitar 3 menit dengan kecepatan 30 fps dikonversi menjadi kumpulan citra (*frame*) yang digunakan sebagai dataset. Dari total sekitar 5.400 *frame* mentah, proses *frame capturing* dilakukan secara otomatis menggunakan penerapan *smart sampling*. Pada proses ini, target *frame rate* diturunkan menjadi sekitar 3,3 fps, sehingga tidak semua *frame* disimpan. Selanjutnya, setiap *frame* kandidat dibandingkan dengan frame sebelumnya menggunakan perhitungan perbedaan *histogram* dan nilai *structural similarity index* (SSIM). Hanya *frame* yang memiliki perbedaan visual signifikan yang disimpan, sehingga diperoleh total 594 *frame* citra yang representatif dan siap digunakan untuk tahap anotasi.

Gambar 13. Sampel *frame image*.

4.2.2. Resize

Citra yang digunakan dalam penelitian ini awalnya memiliki resolusi 1920×1080 piksel. Untuk menyamakan ukuran seluruh data dan mengurangi beban komputasi saat proses deteksi, citra kemudian diubah ukurannya menjadi 854×480 piksel. Ukuran ini dipilih karena tetap mempertahankan aspek rasio 16:9 dan juga detail objek penting dan ringan untuk diproses oleh model Mask R-CNN. Setelah proses *resizing* selesai, citra-citra tersebut selanjutnya digunakan dalam tahap anotasi untuk memberikan label pada setiap objek yang ingin dideteksi oleh model.

4.2.3. Anotasi Data

Pada tahap ini, setiap objek bangunan pada area fakultas dalam citra dianotasi secara manual menggunakan *platform* Roboflow. Proses anotasi dilakukan dengan cara menggambar *polygon* yang mengikuti kontur bangunan pada citra, sehingga terbentuk *mask* yang secara presisi menandai area objek. Pendekatan ini lebih akurat dibandingkan hanya menggunakan kotak pembatas (*bounding box*), karena mampu merepresentasikan bentuk bangunan yang tidak selalu berbentuk persegi panjang. Anotasi dilakukan pada seluruh dataset yang terdiri dari 594 citra, dan hasilnya disimpan dalam format *COCO JSON*, yang berisi informasi koordinat *polygon*, kategori objek yang diperlukan untuk pelatihan dan evaluasi model Mask R-CNN.

Gambar 14. Proses anotasi data.

4.3. Pembagian Dataset

Setelah semua citra selesai dianotasi menggunakan Roboflow dengan teknik *polygon mask*, dataset yang berjumlah 594 citra kemudian dibagi ke dalam tiga subset menggunakan fitur *dataset split* yang tersedia pada *platform* Roboflow. Proses pembagian dilakukan dengan metode *simple random sampling* dengan rasio 70:20:10. Dari hasil pembagian tersebut, sebanyak 415 citra (70%) digunakan sebagai data *training* untuk melatih model Mask R-CNN agar mampu mempelajari pola visual serta karakteristik objek bangunan pada area fakultas UNILA. Selanjutnya, 119 citra (20%) digunakan sebagai data *validation* yang berfungsi untuk mengevaluasi performa model selama proses pelatihan, membantu penyesuaian *hyperparameter*, serta mencegah terjadinya *overfitting*. Sementara itu, 60 citra (10%) digunakan sebagai data *testing* yang tidak dilibatkan dalam proses pelatihan maupun validasi, sehingga dapat memberikan gambaran performa akhir model secara objektif dalam mendeteksi dan melakukan segmentasi gedung fakultas di UNILA. Dataset yang telah terbagi ini kemudian digunakan pada tahap selanjutnya, yaitu pelatihan model Mask R-CNN.

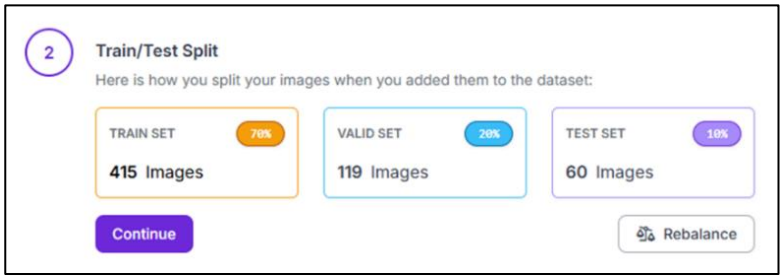

Gambar 15. Ilustrasi pembagian dataset di Roboflow.

4.4. *Training* Model

Pada tahap ini, pelatihan model Mask R-CNN dilakukan menggunakan dataset berformat *COCO* yang terdiri dari 594 citra hasil ekstraksi *frame* video drone beserta anotasi *polygon mask* untuk setiap bangunan fakultas di Universitas Lampung. Format *COCO* dipilih karena menyediakan struktur anotasi yang mencakup *bounding box*, *segmentation mask*, dan label kategori, sehingga dapat diintegrasikan secara langsung dengan modul deteksi objek pada *framework PyTorch* dan memastikan konsistensi antara data latih dan evaluasi.

Model yang digunakan adalah Mask R-CNN dengan *backbone* ResNet-50 *Feature Pyramid Network* (FPN). ResNet-50 berperan sebagai ekstraktor fitur, sedangkan FPN memungkinkan representasi fitur *multi-skala* yang penting dalam mendeteksi objek bangunan dengan variasi ukuran dan perspektif pada citra udara.

Pelatihan dijalankan menggunakan *GPU NVIDIA Tesla T4* pada *platform Kaggle* dan *Google Colab*. Data dimuat melalui *DataLoader* dengan pengaturan *batch size* 2, *num_workers* 2, dan *pin_memory True*. Ukuran *batch* yang kecil dipilih untuk menyesuaikan keterbatasan memori GPU, mengingat kompleksitas komputasi arsitektur Mask R-CNN, sementara konfigurasi *DataLoader* dioptimalkan agar proses *transfer* data tidak menjadi hambatan selama *training*.

Optimisasi parameter dilakukan menggunakan AdamW dengan *learning rate* awal 0,0005 dan *weight decay* 0,0005. *Learning rate* kemudian disesuaikan secara dinamis menggunakan *scheduler* berbasis *warmup* dan *cosine annealing* untuk menjaga stabilitas konvergensi. Jumlah *epoch* maksimum ditetapkan 50 dengan mekanisme *early stopping* (*patience* 5 dan *min_delta* 0,001) agar pelatihan dihentikan ketika peningkatan mAP pada data validasi mulai stagnan.

Evaluasi dilakukan pada setiap akhir *epoch* menggunakan *COCOeval* dengan fokus pada metrik segmentasi, yaitu mAP, AP50, dan AP75. Seluruh nilai *loss* dan metrik evaluasi dicatat secara sistematis, dan model terbaik disimpan berdasarkan peningkatan mAP validasi. Berdasarkan serangkaian penyesuaian tersebut, diperoleh kombinasi *hyperparameter* yang memberikan keseimbangan antara stabilitas pelatihan, efisiensi komputasi, dan performa segmentasi pada dataset penelitian. Rincian konfigurasi tersebut ditampilkan pada Tabel 3.

Tabel 3. Nilai *Hyperparameter Tuning Mask R-CNN.*

Nama Parameter	**Nilai**
Epoch	50
Batch Size	2
Learning Rate	0.0005
Optimizer	*AdamW*
Weight Decay	0.0005
Mixed Precision (AMP)	Aktif (dengan *GradScaler*)
Gradient Clipping	1.0
Early Stopping	Aktif (*patience* = 5)
Evaluasi Validasi	*COCOeval* (mAP, AP50, AP75, IoU)

Konfigurasi *hyperparameter* yang ditampilkan pada Tabel 3 diperoleh melalui beberapa percobaan awal dengan mengamati dinamika *loss* dan tren mAP pada data validasi. Parameter yang dipilih merepresentasikan kombinasi yang memberikan konvergensi stabil serta performa segmentasi yang konsisten pada dataset citra drone UNILA.
Jumlah *epoch* maksimum ditetapkan sebanyak 50 untuk memberikan ruang pembelajaran yang memadai, sementara mekanisme *early stopping* digunakan agar pelatihan dapat dihentikan ketika peningkatan mAP mulai stagnan. Strategi ini membantu mencegah *overfitting* sekaligus meningkatkan efisiensi komputasi. Ukuran *batch size* sebesar 2 dipilih dengan mempertimbangkan keterbatasan memori *GPU Tesla T4*, namun stabilitas pembelajaran tetap terjaga melalui pengaturan *gradien* dan optimasi proses *data loading*.

Optimisasi dilakukan menggunakan *AdamW* dengan *learning rate* awal 0,0005 dan *weight decay* 0,0005 sebagaimana tercantum pada Tabel 3. Nilai *learning rate* kemudian disesuaikan secara dinamis menggunakan *scheduler* berbasis *warmup* dan *cosine annealing*, sehingga pada fase awal pelatihan model dapat melakukan eksplorasi parameter secara lebih luas, kemudian secara bertahap memperhalus pembaruan bobot pada fase akhir untuk mencapai konvergensi yang lebih stabil.

Selain itu, pelatihan dilengkapi dengan *Automatic Mixed Precision* (AMP) menggunakan *GradScaler* untuk meningkatkan efisiensi komputasi dan mengurangi konsumsi memori GPU. Penerapan *gradient clipping* dengan batas maksimum 1.0 juga membantu menjaga kestabilan nilai gradien selama proses *backpropagation*. Secara keseluruhan, kombinasi parameter pada Tabel 3 dirancang untuk mencapai keseimbangan antara efisiensi komputasi, stabilitas pelatihan, dan kualitas segmentasi pada data validasi.

Model Mask R-CNN pada penelitian ini menggunakan pendekatan *transfer learning*, yaitu dengan memanfaatkan bobot awal ResNet-50 FPN yang sudah dilatih sebelumnya pada dataset *COCO*. Dengan menggunakan bobot pralatih ini, proses *training* menjadi lebih cepat dan lebih stabil karena model sudah memiliki pemahaman dasar terhadap pola visual umum seperti tepi, tekstur, dan bentuk geometris.

Namun, seluruh parameter model tetap dilatih ulang (*fine-tuning*) agar bisa menyesuaikan diri dengan karakteristik citra drone UNILA. Penyesuaian juga dilakukan pada bagian *box predictor* dan *mask predictor* supaya jumlah kelas sesuai dengan 48 kategori bangunan pada dataset penelitian. Hal ini penting karena citra drone memiliki perbedaan yang cukup signifikan dibandingkan dataset *COCO*, baik dari sisi sudut pengambilan gambar yang miring, variasi pencahayaan di lapangan, ukuran bangunan yang relatif kecil, maupun latar belakang yang lebih kompleks seperti pepohonan dan area terbuka.

Pada bagian *backbone*, lapisan awal biasanya menangkap pola sederhana seperti garis dan tekstur, sedangkan semakin dalam lapisannya, model mulai membentuk representasi yang lebih kompleks, misalnya kontur atap dan batas struktur bangunan. Untuk melihat bagaimana fitur tersebut terbentuk pada berbagai tingkat kedalaman jaringan, dilakukan visualisasi *feature map* pada beberapa lapisan *backbone*.

Berikut ini merupakan visualisasi *feature map* pada lapisan awal dan lapisan dalam *backbone* yang ditunjukkan pada Gambar 16.

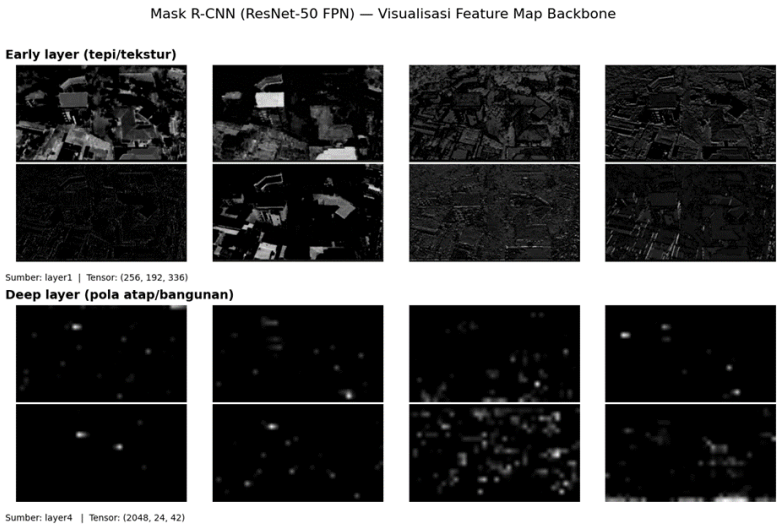

Gambar 16. Visualisasi *feature map* dari *backbone* ResNet-50.

Setelah fitur diekstraksi oleh backbone, hasil tersebut kemudian diproses lebih lanjut oleh Feature Pyramid Network (FPN). FPN membantu model menggabungkan informasi dari beberapa tingkat resolusi sekaligus, sehingga objek dengan ukuran yang berbeda-beda tetap bisa dikenali dengan baik dalam satu citra. Hal ini penting pada citra drone karena ukuran bangunan dalam frame bisa terlihat kecil atau besar tergantung jarak dan sudut pengambilan gambar.

Pada level yang lebih rendah, seperti P2, *feature map* masih menyimpan detail spasial yang cukup tinggi, sehingga cocok untuk mendeteksi objek yang relatif kecil atau bagian bangunan yang detail. Sementara itu, pada level yang lebih tinggi seperti P5, informasi yang terbentuk sudah lebih abstrak dan fokus pada struktur atau bentuk secara umum, sehingga lebih efektif untuk mengenali objek yang ukurannya lebih besar. Dengan kombinasi beberapa level ini, model dapat menangani variasi ukuran bangunan secara lebih fleksibel. Visualisasi *feature map multi-scale* yang dihasilkan oleh FPN ditampilkan pada Gambar 17.

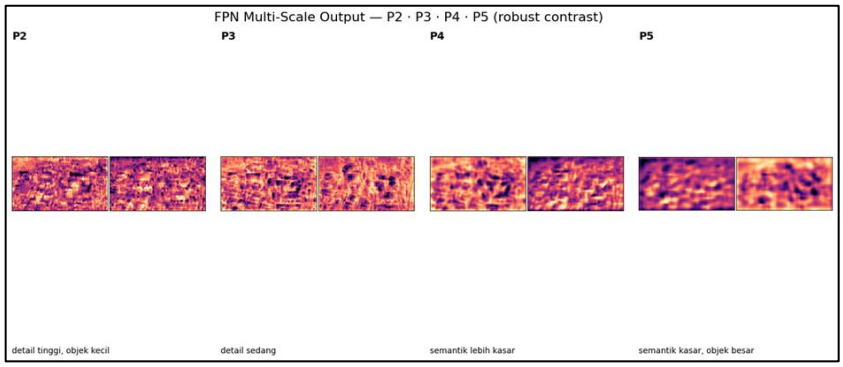

Gambar 17. Visualisasi *multi-scale feature map* dari FPN (P2, P3, P4, P5).

Lalu, *feature map* yang telah diolah oleh FPN diproses pada tahap *Region Proposal Network* (RPN). Pada bagian ini, model mulai mengidentifikasi area-area dalam citra yang kemungkinan besar berisi objek bangunan. RPN menghasilkan sejumlah kandidat wilayah atau *proposal boxes*, yang masing-masing diberi skor berdasarkan tingkat keyakinan bahwa area tersebut mengandung objek. Proposal dengan skor yang lebih tinggi akan dipilih dan diteruskan ke tahap berikutnya.

Proposal yang telah dipilih kemudian diproses menggunakan *RoIAlign*. Pada tahap ini, bagian *feature map* yang sesuai dengan lokasi *Region of Interest* (RoI) diekstraksi dan diubah ukurannya menjadi seragam. Penyamaan ukuran ini penting agar setiap proposal

memiliki dimensi fitur yang konsisten sebelum masuk ke tahap klasifikasi dan pembentukan mask segmentasi. Dengan cara ini, meskipun ukuran awal wilayah berbeda-beda, model tetap dapat memprosesnya secara stabil dan terstruktur. Hasil proses RoIAlign untuk beberapa proposal pertama ditampilkan pada Gambar 18.

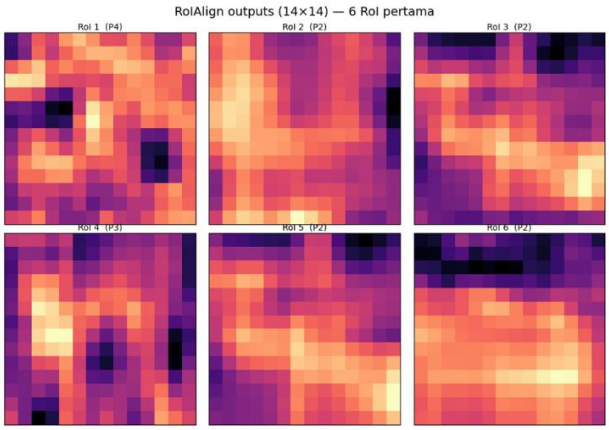

Gambar 18. Hasil RoIAlign untuk enam RoI pertama.

Setelah setiap proposal diproses melalui RoIAlign dan memiliki ukuran fitur yang seragam, tahap selanjutnya adalah detection head. Pada bagian ini, feature map diproses melalui tiga jalur utama yang berjalan secara paralel. Jalur pertama bertugas melakukan klasifikasi untuk menentukan kelas bangunan yang terdeteksi. Jalur kedua melakukan *bounding box regression* untuk memperbaiki posisi dan ukuran kotak prediksi agar semakin mendekati ground truth. Sementara itu, jalur ketiga atau *mask head* menghasilkan segmentasi objek pada tingkat piksel sehingga bentuk bangunan dapat terpetakan secara lebih detail.

Dengan tiga jalur ini, model tidak hanya mengetahui objek apa yang terdeteksi dan di mana lokasinya, tetapi juga mampu menggambarkan area bangunan secara presisi melalui mask segmentasi. Hal ini menjadi bagian penting dalam penelitian ini, karena hasil mask tersebut kemudian digunakan untuk menghitung luas area bangunan. Visualisasi keluaran dari detection head ditampilkan pada Gambar 19.

Gambar 19. Visualisasi keluaran *detection head*.

Untuk memperjelas bagaimana arsitektur Mask R-CNN tersebut diimplementasikan dalam penelitian ini, berikut ditampilkan potongan kode utama yang digunakan untuk membangun model. Kode ini menunjukkan proses inisialisasi *backbone*, serta penyesuaian bagian *box predictor* dan *mask predictor* agar sesuai dengan jumlah kelas pada dataset penelitian.

Kode Program 1. Struktur utama model Mask R-CNN.

```
def build_model(num_classes, backbone_name="resnet50_fpn_v2", hidden_layer=256):
    try:
        if backbone_name == "resnet50_fpn_v2":
            model =
torchvision.models.detection.maskrcnn_resnet50_fpn_v2(weights="DEFAULT")
        else:
            raise ValueError
    except Exception:
        print("Fallback to resnet50_fpn (v1) ...")
        model =
torchvision.models.detection.maskrcnn_resnet50_fpn(weights="DEFAULT")

    in_features = model.roi_heads.box_predictor.cls_score.in_features
    model.roi_heads.box_predictor = FastRCNNPredictor(in_features, num_classes)

    in_features_mask = model.roi_heads.mask_predictor.conv5_mask.in_channels
    model.roi_heads.mask_predictor = MaskRCNNPredictor(in_features_mask,
hidden_layer, num_classes)

    return model

model = build_model(num_classes, backbone_name="resnet50_fpn_v2").to(device)
```

Pada potongan kode tersebut, dilakukan penyesuaian pada bagian *detection head* Mask R-CNN agar jumlah kelas sesuai dengan dataset penelitian. Bagian *box_predictor* diganti menggunakan FastRCNNPredictor, yang bertugas melakukan klasifikasi objek sekaligus memperbaiki posisi dan ukuran *bounding box* melalui regresi. Sementara itu, *mask_predictor* diganti menggunakan MaskRCNNPredictor untuk menghasilkan segmentasi objek pada tingkat piksel.

Nilai *in_features_mask* diambil dari *conv5_mask.in_channels*, yaitu jumlah saluran keluaran pada cabang mask sebelum lapisan prediksi akhir. Parameter *hidden_layer* = 256 digunakan sebagai ukuran lapisan tersembunyi pada *mask head* agar kapasitas representasi tetap cukup untuk merepresentasikan bentuk bangunan, namun tetap efisien dari sisi komputasi. Dengan penyesuaian ini, model mampu menghasilkan tiga keluaran utama, yaitu label kelas, koordinat *bounding box*, dan *mask* segmentasi yang merepresentasikan area bangunan secara detail.

Setelah struktur model selesai dibangun dan disesuaikan, tahap berikutnya adalah proses pelatihan melalui mekanisme training loop untuk memperbarui bobot model secara iteratif berdasarkan data latih dan menghitung nilai loss pada setiap epoch. Implementasi proses tersebut ditampilkan pada Kode Program 2.

Kode Program 2. Training loop model Mask R-CNN.

```
for epoch in range(1, cfg.EPOCHS + 1):
    model.train()
    epoch_loss = 0.0

    # --- Training step ---
    for images, targets in train_loader:
        images  = [img.to(device) for img in images]
        targets = [{k: v.to(device) for k, v in t.items()} for t in targets]

        optimizer.zero_grad(set_to_none=True)
        with autocast(device_type, enabled=cfg.MIXED_PRECISION):
            loss_dict = model(images, targets)
            losses = sum(loss for loss in loss_dict.values())

        scaler.scale(losses).backward()
        torch.nn.utils.clip_grad_norm_(model.parameters(), 1.0)
        scaler.step(optimizer)
        scaler.update()
        epoch_loss += losses.item()

    scheduler.step()
```

Model yang telah dibangun kemudian dilatih menggunakan mekanisme *training loop* sebagaimana ditampilkan pada Kode Program 2. Proses ini dijalankan dalam beberapa *epoch*, di mana pada setiap *epoch* model masuk ke mode *training* dan data latih diproses dalam beberapa *batch*. Setiap *batch* citra beserta anotasinya dipindahkan ke perangkat komputasi, lalu dilakukan komputasi awal untuk menghasilkan beberapa komponen *loss* yang berasal dari klasifikasi, *bounding box regression*, dan *mask* segmentasi. Seluruh komponen tersebut dijumlahkan sebagai total loss sebelum dilakukan proses backward pass untuk memperbarui bobot model.

Pada tahap pembaruan bobot, digunakan *Automatic Mixed Precision* (AMP) dengan bantuan *GradScaler* agar proses komputasi lebih efisien dan tetap stabil. Untuk menjaga agar nilai gradien tidak terlalu besar, diterapkan juga *gradient clipping* sebelum *optimizer* melakukan update parameter. Nilai *loss* dari tiap *batch* diakumulasikan menjadi total *loss* per *epoch*, kemudian *scheduler* dijalankan untuk menyesuaikan *learning rate* secara bertahap sesuai strategi yang telah ditentukan.

Training loop pada Kode Program 2 berfokus pada proses pembelajaran di data latih. Untuk memastikan bahwa model tidak hanya belajar dengan baik pada data *training* tetapi juga mampu melakukan generalisasi, dilakukan tahap validasi pada akhir setiap *epoch*. Proses validasi, perhitungan metrik menggunakan *COCOeval*, penyimpanan *checkpoint* model terbaik, serta penerapan *early stopping* ditampilkan pada Kode Program 3.

Kode Program 3. Validasi *COCOeval*, *checkpoint*, dan *early stopping*.

```
# --- Validation & Evaluation ---
    segm_stats, _ = coco_eval_on_loader(model, val_loader, new2name, iou_type="segm")
    mAP, AP50, AP75 = float(segm_stats[0]), float(segm_stats[1]), float(segm_stats[2])

    # --- Checkpoint & Early Stopping ---
    if mAP > best_map + cfg.MIN_DELTA:
        best_map, best_epoch, no_improve = mAP, epoch, 0
        torch.save(model.state_dict(), "best_model.pth")
    else:
        no_improve += 1

    if no_improve >= cfg.PATIENCE:
        print("Early stopping triggered")
        break
```

Pada Kode Program 3 ditambahkan tahap validasi untuk mengevaluasi performa model di akhir setiap *epoch*. Pada tahap ini, model menghasilkan prediksi pada data validasi, lalu hasilnya dibandingkan dengan *ground truth* menggunakan *COCOeval* dengan fokus pada metrik segmentasi. Nilai mAP digunakan sebagai indikator utama, sedangkan AP50 dan AP75 membantu melihat performa model pada ambang IoU tertentu.

Nilai mAP validasi menjadi dasar dalam menentukan apakah model mengalami peningkatan atau tidak. Jika terjadi peningkatan yang melebihi batas minimum (*min_delta*), maka bobot model akan disimpan sebagai *best_model.pth*. Dengan cara ini, model terbaik dipilih berdasarkan performa validasi tertinggi yang benar-benar dicapai selama pelatihan, bukan hanya berdasarkan *epoch* terakhir.

Sebaliknya, jika tidak ada peningkatan performa dalam beberapa *epoch* berturut-turut sesuai nilai *patience*, maka mekanisme *early stopping* akan menghentikan pelatihan. Strategi ini membantu menjaga agar model tidak terus dilatih ketika peningkatannya sudah stagnan, sekaligus mengurangi risiko *overfitting*. Seluruh nilai evaluasi juga dicatat secara berkala sehingga perkembangan performa model dari awal hingga akhir pelatihan dapat dianalisis dengan lebih jelas.

Selama proses pelatihan berlangsung, seluruh metrik pada setiap *epoch* seperti nilai *loss*, mAP, AP50, AP75, serta *learning rate* dicatat ke dalam *file log* berformat CSV. Pencatatan ini dilakukan agar perkembangan performa model dapat dipantau secara bertahap dari awal hingga akhir pelatihan. Dengan adanya data *log* tersebut, perubahan nilai *loss* dan metrik evaluasi dapat dianalisis secara lebih terstruktur, bukan hanya berdasarkan hasil akhir saja.

Data yang telah direkam kemudian divisualisasikan dalam bentuk grafik untuk melihat tren penurunan *loss* pada data latih serta peningkatan performa pada data validasi dari *epoch* ke *epoch*. Melalui visualisasi ini, dapat diamati apakah proses pelatihan berjalan stabil, apakah model mulai mengalami stagnasi, serta bagaimana pengaruh mekanisme *early stopping* terhadap durasi pelatihan. Selain itu, perbandingan antara performa *training* dan validasi juga membantu melihat kemampuan generalisasi model terhadap data yang tidak digunakan dalam proses pembelajaran. Grafik *training* dan validasi tersebut menjadi dasar utama dalam pembahasan berikutnya untuk mengevaluasi kualitas hasil pelatihan model secara lebih mendalam.

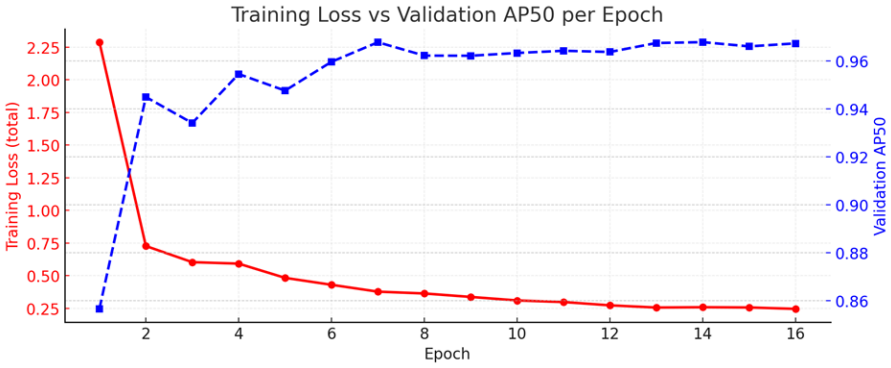

Gambar 20. Grafik *training loss* dan validasi metrik AP50.

Berdasarkan Gambar 20, nilai *training loss* (garis merah) mengalami penurunan yang sangat signifikan pada tahap awal pelatihan. Pada *epoch* pertama, nilai *loss* berada di atas 2,2, kemudian turun drastis menjadi sekitar 0,7 pada *epoch* kedua. Penurunan yang tajam ini menunjukkan bahwa model mampu menyesuaikan bobot awalnya dengan cepat terhadap pola pada data latih. Setelah fase awal tersebut, nilai *loss* terus menurun secara bertahap hingga mendekati 0,25 dan kemudian cenderung stabil hingga akhir pelatihan. Pola ini menunjukkan bahwa proses optimasi berjalan secara terarah dan pembaruan parameter model semakin terkendali seiring bertambahnya *epoch*.

Sementara itu, nilai AP50 pada data validasi (garis biru) menunjukkan tren peningkatan yang konsisten. Pada *epoch* pertama, AP50 berada di sekitar 0,86, lalu meningkat mendekati 0,95 pada *epoch* kedua. Pada *epoch-epoch* selanjutnya, nilainya terus bertambah hingga berada pada kisaran 0,96–0,97 dan relatif stabil sampai akhir pelatihan. Kenaikan yang cepat di awal kemudian diikuti kestabilan pada nilai tinggi menunjukkan bahwa model tidak hanya menyesuaikan diri pada data latih, tetapi juga mampu mempertahankan performa segmentasi pada data validasi. Pola ini memperlihatkan bahwa proses pelatihan berlangsung stabil tanpa adanya lonjakan *error* yang mengarah pada *overfitting*.

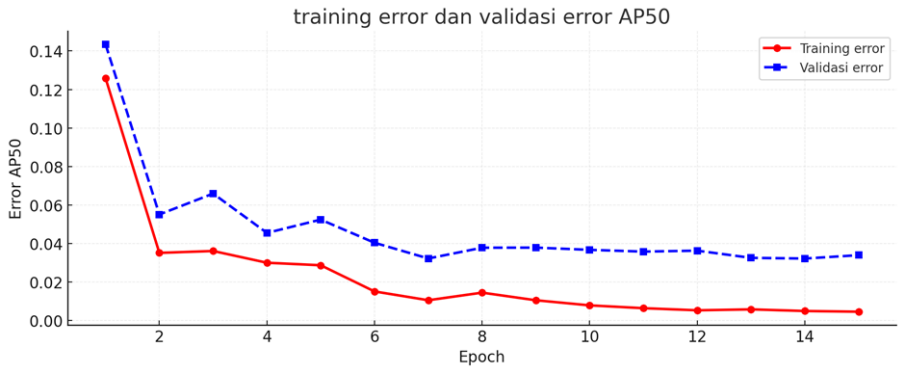

Gambar 21. Grafik *training error* dan validasi *error* AP50.

Sejalan dengan grafik sebelumnya, Gambar 21 menampilkan perkembangan nilai *error* untuk metrik AP50 selama proses pelatihan. *Training error* (garis merah) mengalami penurunan yang cukup drastis pada tahap awal, dari sekitar 0,12 pada *epoch* pertama menjadi kurang lebih 0,03 pada *epoch* kedua. Setelah penurunan awal tersebut, nilainya terus berkurang secara bertahap hingga mendekati 0,005 pada kisaran *epoch* ke-13 sampai ke-16. Tren ini menunjukkan bahwa kesalahan prediksi pada data latih semakin kecil seiring dengan bertambahnya jumlah *epoch*, sehingga model semakin mampu menyesuaikan parameter terhadap pola objek bangunan.

Pada data validasi, *error* AP50 (garis biru) juga menunjukkan pola yang serupa. Nilainya turun cukup tajam di awal pelatihan, dari sekitar 0,14 menjadi mendekati 0,05 pada *epoch* kedua. Pada *epoch* berikutnya, penurunannya berlangsung lebih perlahan dan kemudian stabil di kisaran 0,03–0,04 mulai sekitar *epoch* ke-10 hingga akhir pelatihan. Perbedaan kecil antara *training error* yang masih sedikit menurun dan validasi *error* yang sudah relatif mendatar menunjukkan bahwa proses pembelajaran telah memasuki fase stabil.

Tambahan *epoch* tidak lagi memberikan penurunan *error* yang signifikan pada data validasi, namun juga tidak memperlihatkan peningkatan *error* yang mengarah pada *overfitting*. Pola ini mengindikasikan bahwa model telah mencapai titik keseimbangan antara pembelajaran dan generalisasi.

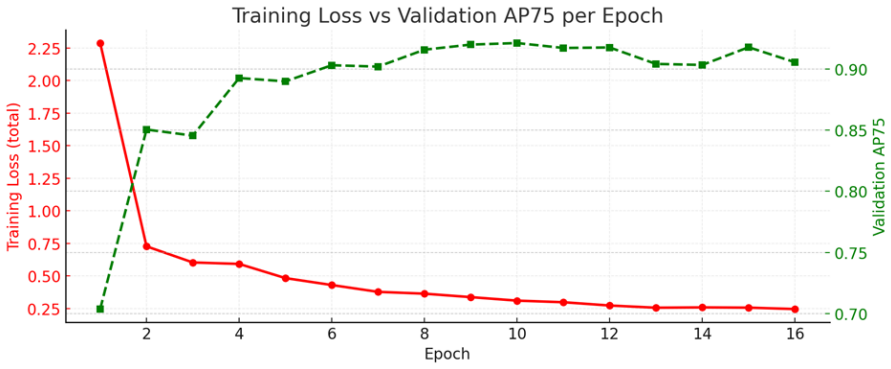

Gambar 22. Grafik *training loss* dan validasi metrik AP75.

Sebagai kelanjutan dari pembahasan AP50, Gambar 22 menampilkan hubungan antara *training loss* dan metrik validasi AP75. Garis merah yang merepresentasikan *training loss* masih menunjukkan pola yang konsisten dengan grafik sebelumnya, yaitu penurunan yang tajam pada tahap awal pelatihan kemudian semakin landai hingga akhir *epoch*. Karena nilai *loss* berasal dari proses optimasi yang sama, bentuk kurvanya relatif serupa dengan grafik sebelumnya dan mencerminkan proses pembelajaran yang stabil.

Perbedaan utama pada grafik ini terletak pada perkembangan nilai AP75 (garis hijau). Pada *epoch* pertama, nilainya masih berada di sekitar 0,70, kemudian meningkat cukup signifikan pada beberapa *epoch* awal hingga mendekati 0,85. Selanjutnya, nilai AP75 terus bertambah dan melampaui 0,90 sekitar *epoch* ke-6, sebelum akhirnya mencapai kisaran di atas 0,92 dan bergerak relatif stabil dengan sedikit fluktuasi pada *epoch* akhir. Jika dibandingkan dengan AP50, kenaikan AP75 memang terlihat lebih bertahap. Hal ini wajar karena ambang IoU 0,75 menuntut kesesuaian batas segmentasi yang lebih presisi. Dengan demikian, meskipun model sudah mampu mencapai akurasi tinggi pada AP50 dalam waktu singkat, peningkatan kualitas segmentasi yang lebih detail dan ketat baru terlihat secara bertahap melalui perkembangan AP75.

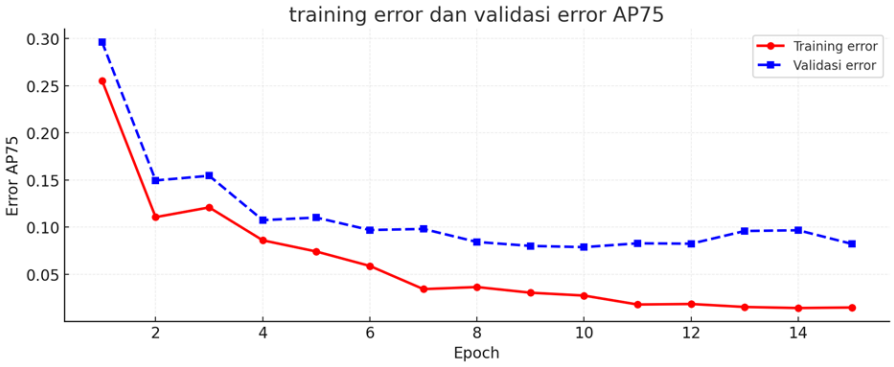

Gambar 23. Grafik *training error* dan validasi *error* AP75.

Gambar 23 menampilkan perkembangan *training error* dan *validasi error* untuk metrik AP75. Karena evaluasi dilakukan pada ambang IoU yang lebih ketat, nilai *error* pada grafik ini secara umum memang lebih tinggi dibandingkan dengan *error* AP50. Garis merah menunjukkan bahwa *training error* mengalami penurunan yang cukup signifikan pada tahap awal, dari sekitar 0,25 pada *epoch* pertama menjadi kurang lebih 0,11 pada *epoch* kedua. Setelah fase awal tersebut, penurunannya berlangsung lebih bertahap hingga mendekati 0,02 pada akhir pelatihan. Tren ini mencerminkan bahwa model semakin mampu memperkecil kesalahan segmentasi meskipun menggunakan kriteria evaluasi yang lebih ketat.

Pada data validasi, garis biru yang merepresentasikan *error* AP75 juga menunjukkan pola penurunan yang serupa. Nilainya turun dari sekitar 0,29 pada *epoch* pertama menjadi sekitar 0,15 pada *epoch* kedua, kemudian terus membaik hingga mencapai kisaran 0,08 pada sekitar *epoch* ke-9 hingga ke-10. Setelah itu, nilai *error* bergerak relatif stabil dengan sedikit fluktuasi pada beberapa *epoch* akhir. Meskipun secara *absolut error* AP75 lebih tinggi dibandingkan AP50, tren penurunannya tetap konsisten dan tidak menunjukkan kenaikan tajam pada fase akhir pelatihan. Kondisi ini mengindikasikan bahwa model tidak hanya mampu mendeteksi objek, tetapi juga semakin presisi dalam mengikuti batas segmentasi ketika dievaluasi dengan ambang IoU yang lebih tinggi.

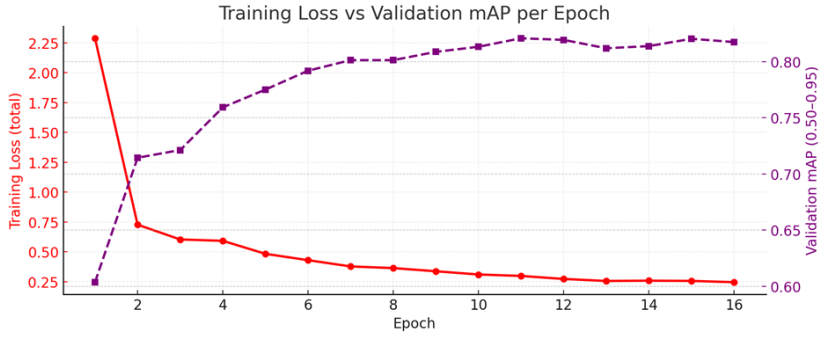

Gambar 24. Grafik *training loss* dan validasi metrik mAP.

Sebagai indikator performa secara menyeluruh, Gambar 24 menampilkan hubungan antara *training loss* (garis merah) dan nilai mAP pada data validasi (garis ungu). Kurva *training loss* masih menunjukkan tren penurunan yang konsisten seperti pada grafik sebelumnya, sehingga perhatian utama pada grafik ini lebih difokuskan pada perkembangan mAP sebagai ukuran kinerja model secara keseluruhan. Pada *epoch* pertama, nilai mAP berada di sekitar 0,60, yang menunjukkan bahwa kemampuan segmentasi model pada berbagai ambang IoU masih belum stabil.

Seiring bertambahnya *epoch*, nilai mAP meningkat cukup signifikan pada tahap awal pelatihan, melampaui 0,75 dan terus naik hingga mendekati 0,80 pada pertengahan proses *training*. Memasuki *epoch* ke-7 hingga ke-11, mAP kembali mengalami peningkatan dan mencapai kisaran tertinggi sekitar 0,82. Setelah itu, nilainya cenderung stabil dengan fluktuasi kecil hingga akhir pelatihan. Stabilitas pada fase akhir ini menunjukkan bahwa performa model telah mencapai titik yang relatif konstan pada data validasi. Mengingat mAP merupakan rata-rata dari berbagai ambang IoU, capaian yang konsisten di atas 0,80 menggambarkan bahwa model mampu mempertahankan kualitas deteksi dan segmentasi secara seimbang pada berbagai tingkat evaluasi.

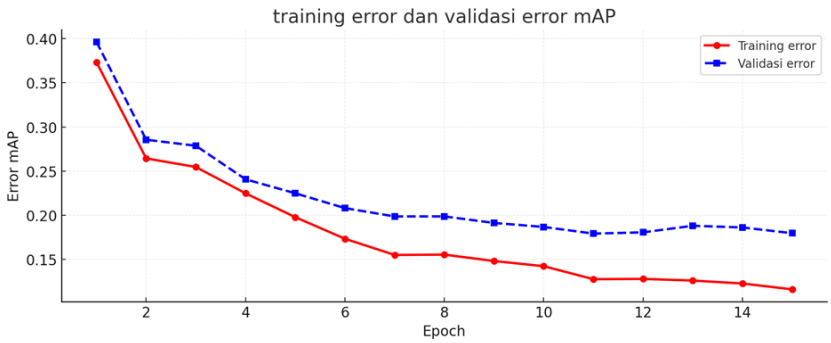

Gambar 25. Grafik *training error* dan validasi *error* mAP.

Jika pada grafik sebelumnya peningkatan mAP terlihat stabil, maka Gambar 25 menampilkan perkembangan yang sejalan dari sisi *error*, baik pada data latih maupun data validasi. Garis merah menunjukkan bahwa *training error* menurun secara konsisten, dari sekitar 0,37 pada *epoch* pertama menjadi kurang lebih 0,26 pada *epoch* kedua, lalu terus berkurang secara bertahap hingga mendekati 0,11 pada akhir pelatihan. Tren ini menunjukkan bahwa kesalahan prediksi secara keseluruhan semakin kecil seiring dengan bertambahnya *epoch*.

Pada data validasi, garis biru yang merepresentasikan *error* mAP juga mengalami penurunan yang cukup signifikan di awal pelatihan, dari sekitar 0,39 menjadi 0,28 pada *epoch* kedua. Selanjutnya, nilainya terus membaik hingga berada pada kisaran 0,17–0,18 di pertengahan pelatihan, kemudian bergerak relatif stabil dengan fluktuasi kecil hingga akhir. Mengingat mAP merupakan rata-rata performa pada beberapa ambang IoU, nilai *error* yang lebih tinggi dibandingkan AP50 dan AP75 sebelumnya masih dapat dipahami. Yang lebih penting, tidak terlihat adanya kenaikan tajam pada fase akhir pelatihan, sehingga proses pembelajaran tetap terjaga tanpa indikasi penurunan performa pada data validasi.

Secara keseluruhan, rangkaian grafik *loss*, AP50, AP75, dan mAP menunjukkan pola yang saling mendukung. Penurunan *loss* yang konsisten disertai peningkatan serta kestabilan metrik evaluasi mengindikasikan bahwa proses pelatihan berjalan secara terkontrol. Evaluasi dilakukan pada setiap *epoch* dengan menjadikan mAP sebagai indikator utama dalam memantau kualitas model.

Ketika nilai mAP pada data validasi menunjukkan peningkatan yang lebih baik dibandingkan *epoch* sebelumnya, bobot model disimpan sebagai *best_model.pth*. Mekanisme ini memastikan bahwa model yang digunakan pada tahap pengujian bukan sekadar hasil dari *epoch* terakhir, melainkan parameter dengan performa validasi terbaik. Dengan demikian, evaluasi pada data uji dapat merepresentasikan kemampuan generalisasi model secara lebih objektif terhadap citra yang tidak terlibat dalam proses pelatihan.

4.5. Testing Model

Setelah proses pelatihan selesai dan bobot terbaik diperoleh, tahap berikutnya adalah melakukan pengujian menggunakan data uji yang telah dipisahkan sejak awal. Pada penelitian ini, data uji terdiri dari 60 citra atau sekitar 10% dari total dataset. Data tersebut tidak digunakan dalam proses *training* maupun validasi, sehingga dapat merepresentasikan kondisi yang benar-benar baru bagi model. Pengujian pada data ini bertujuan untuk menilai kemampuan generalisasi model terhadap citra yang belum pernah dilihat sebelumnya.

Proses evaluasi dilakukan menggunakan bobot terbaik (*best_model.pth*) yang dipilih berdasarkan nilai mAP validasi tertinggi selama pelatihan. Pada tahap ini, performa model dianalisis dari dua sisi, yaitu kemampuan mendeteksi lokasi objek melalui *bounding box* dan kemampuan menghasilkan segmentasi objek melalui *mask*. Mengingat tujuan utama penelitian adalah pemetaan bentuk serta estimasi luas bangunan, kualitas segmentasi menjadi fokus utama dalam evaluasi.

Untuk mengukur akurasi prediksi, digunakan metrik standar COCO, yaitu mAP, AP50, dan AP75. Ketiga metrik tersebut membandingkan hasil prediksi model dengan anotasi *ground truth* pada data uji. Melalui evaluasi ini, dapat diketahui sejauh mana model mampu mempertahankan konsistensi dan ketelitian segmentasi bangunan ketika diterapkan pada citra drone di luar data pelatihan.

4.5.1. Analisis Hasil Deteksi dan Segmentasi

Pada tahap ini, analisis difokuskan pada pengamatan langsung terhadap hasil prediksi model Mask R-CNN pada data uji. Jika sebelumnya evaluasi dilakukan melalui metrik kuantitatif seperti mAP, AP50, dan AP75, maka pada bagian ini penilaian dilakukan secara visual untuk melihat kualitas segmentasi secara lebih konkret. Melalui visualisasi tersebut, dapat diamati sejauh mana model mampu mengikuti bentuk bangunan dan menyesuaikan batas segmentasi dengan kontur objek pada citra drone.

Visualisasi yang ditampilkan hanya memperlihatkan mask segmentasi tanpa *bounding box*. Pemilihan ini disesuaikan dengan tujuan utama penelitian, yaitu menganalisis ketepatan bentuk objek serta menghitung luas bangunan berdasarkan hasil segmentasi. Meskipun *bounding box* dapat menunjukkan lokasi objek, representasi tersebut belum

cukup menggambarkan detail bentuk bangunan yang menjadi dasar dalam estimasi luas. Dengan menampilkan mask secara langsung, kesesuaian batas segmentasi pada tingkat piksel dapat diamati dengan lebih jelas, terutama pada bagian tepi bangunan dan area yang berdekatan dengan objek lain.

Gambar 26 menampilkan contoh hasil segmentasi pada data uji. Pada visualisasi tersebut, objek bangunan terlihat berhasil dikenali dan dipetakan mengikuti bentuk aslinya pada citra. Kesesuaian antara *mask* prediksi dan struktur bangunan pada gambar menjadi indikasi awal bahwa model mampu mempertahankan kualitas segmentasi ketika diterapkan pada data yang tidak digunakan selama pelatihan.

Gambar 26. Hasil testing model Mask R-CNN.

Berdasarkan hasil pengujian pada data testing yang divisualisasikan pada Gambar 26, model Mask R-CNN menunjukkan performa segmentasi yang stabil dalam mengenali bangunan pada citra drone. Pada data uji, diperoleh nilai rata-rata mAP sebesar 82,03%. Nilai ini menunjukkan bahwa sebagian besar kelas bangunan dapat tersegmentasi dengan akurasi yang cukup konsisten.

Jika dianalisis per kelas, terlihat adanya variasi performa. Kelas FKIP 25 mencatat nilai mAP tertinggi sebesar 98,60%, sedangkan FMIPA 10 memiliki nilai terendah sebesar 46,85%. Perbedaan ini mengindikasikan bahwa tingkat kesulitan segmentasi tidak merata pada setiap kategori bangunan. Faktor yang dapat memengaruhi variasi tersebut antara lain jumlah data latih yang berbeda antar kelas, ukuran bangunan yang relatif kecil, serta gangguan visual seperti bayangan atau vegetasi di sekitar objek.

Selain mAP, nilai AP50 dan AP75 juga digunakan untuk melihat performa pada ambang IoU yang berbeda. Pada data testing, model memperoleh AP50 sebesar 94,52% dan AP75 sebesar 89,50%. Nilai AP50 yang tinggi menunjukkan bahwa sebagian besar objek berhasil terdeteksi dengan *overlap* minimum 0,50, sedangkan nilai AP75 yang tetap berada pada kisaran tinggi menunjukkan bahwa kualitas batas segmentasi masih terjaga meskipun menggunakan kriteria evaluasi yang lebih ketat.

Jika dibandingkan dengan hasil pada tahap validasi, performa model menunjukkan pola yang relatif konsisten. Pada data validasi, diperoleh mAP sebesar 81,74%, AP50 sebesar 96,73%, dan AP75 sebesar 90,55%. Selisih antara validasi dan testing tidak terlalu besar, sehingga performa model pada data uji tetap berada dalam rentang yang sejalan dengan hasil selama pelatihan. Perbandingan ini memberikan gambaran bahwa model tidak mengalami penurunan performa yang signifikan ketika diterapkan pada data yang belum pernah dilihat sebelumnya.

Untuk melihat perbandingan tersebut secara lebih ringkas, hasil terbaik pada tahap validasi selama training serta hasil evaluasi pada data testing disajikan dalam satu tabel. Penyajian ini memudahkan pengamatan terhadap konsistensi nilai mAP, AP50, dan AP75 antara fase pelatihan dan pengujian. Rangkuman performa model pada kedua fase tersebut ditampilkan pada Tabel 4.

Tabel 4. Nilai terbaik performa model Mask R-CNN validasi selama *training* dan pada pengujian.

Metrik	**Validasi (*Training*)**	***Testing***
mAP	81,74%	82,03%
AP50	96,73%	94,52%
AP75	90,55%	89,50%
Mean IoU	-	88,12%

Tabel 4 menyajikan perbandingan performa terbaik model pada tahap validasi selama proses *training* dengan hasil pengujian pada data testing. Pada tahap validasi, model mencapai mAP sebesar 81,74%, dengan AP50 sebesar 96,73% dan AP75 sebesar 90,55%. Nilai tersebut diperoleh pada saat pelatihan dihentikan karena peningkatan mAP mulai stagnan, sehingga bobot yang disimpan merepresentasikan performa validasi tertinggi selama proses *training* berlangsung.

Ketika bobot yang sama diterapkan pada data *testing*, diperoleh mAP sebesar 82,03%, dengan AP50 sebesar 94,52% dan AP75 sebesar 89,50%. Selisih antara nilai validasi dan testing relatif kecil, sehingga performa model pada data uji tetap berada dalam rentang yang sejalan dengan hasil selama pelatihan. Selain itu, nilai mean IoU sebesar 88,12% pada data *testing* memperlihatkan bahwa segmentasi yang dihasilkan cukup presisi dalam mengikuti batas bangunan.

Melalui perbandingan ini, dapat diamati bahwa performa model pada fase pengujian tidak mengalami penurunan yang signifikan dibandingkan fase validasi. Data pada Tabel 4 menjadi dasar untuk melanjutkan evaluasi yang lebih rinci pada bagian berikutnya, khususnya dalam menganalisis kualitas segmentasi per kelas dan ketepatan estimasi luas bangunan.

4.6. Evaluasi Model

Setelah performa model dibandingkan antara tahap validasi dan pengujian pada Tabel 4, tahap selanjutnya adalah melakukan evaluasi yang lebih terstruktur terhadap hasil prediksi pada data uji. Jika sebelumnya pembahasan berfokus pada gambaran umum performa melalui nilai agregat, maka pada bagian ini analisis dilakukan secara lebih rinci untuk memahami kualitas segmentasi model pada setiap kelas bangunan.

Evaluasi difokuskan pada metrik segmentasi yang digunakan secara standar dalam deteksi dan *instance segmentation*, yaitu *Intersection over Union* (IoU), *Average Precision* (AP), dan *mean Average Precision* (mAP). Metrik IoU digunakan untuk mengukur tingkat tumpang tindih antara *mask* prediksi dan *mask ground truth*. Sementara itu, AP dan mAP memberikan gambaran performa model dengan mempertimbangkan nilai *confidence score* serta berbagai ambang IoU, sehingga evaluasi tidak hanya bergantung pada satu threshold tertentu.

Melalui kombinasi ketiga metrik tersebut, kualitas segmentasi dapat dianalisis dari beberapa sudut pandang, mulai dari kesesuaian batas objek pada tingkat piksel hingga konsistensi performa pada berbagai tingkat evaluasi. Pendekatan ini memungkinkan penilaian yang lebih objektif sebelum dilanjutkan pada tahap berikutnya, yaitu analisis estimasi luas bangunan berdasarkan hasil segmentasi.

4.6.1. Evaluasi Hasil Deteksi Objek

Pada bagian ini, evaluasi difokuskan pada kualitas segmentasi objek bangunan dengan membandingkan *mask* hasil prediksi model terhadap anotasi *ground truth*. Analisis dilakukan untuk menilai sejauh mana model mampu mengikuti bentuk serta batas bangunan pada citra drone. Penilaian tidak hanya berdasarkan nilai agregat metrik, tetapi juga melalui pengamatan kesesuaian area segmentasi pada setiap objek.

Untuk mengukur tingkat kesesuaian tersebut, digunakan metrik *Intersection over Union* (IoU). IoU menghitung perbandingan antara luas area irisan (*intersection*) *mask* prediksi dan mask *ground truth* terhadap luas gabungan keduanya (*union*). Secara matematis, nilai ini merepresentasikan proporsi area yang saling tumpang tindih dibandingkan total area yang terlibat. Nilai IoU berada pada rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan tingkat kecocokan yang semakin tinggi antara hasil segmentasi model dan anotasi sebenarnya.

Dalam implementasinya, *mask* prediksi dan mask *ground truth* ditumpang tindihkan pada citra yang sama sehingga perbedaan maupun kesesuaian batas objek dapat diamati secara visual. Pendekatan ini memungkinkan evaluasi dilakukan tidak hanya secara numerik, tetapi juga secara langsung melalui pengamatan bentuk segmentasi pada tiap *instance* bangunan. Visualisasi perbandingan antara *mask* prediksi dan *ground truth* ditampilkan pada Gambar 27 sebagai ilustrasi hasil segmentasi model pada data uji.

Gambar 27. Visualisasi *mask ground truth* dan *mask* prediksi.

Selain membandingkan kesesuaian *mask* dengan *ground truth*, performa model juga dapat diamati melalui visualisasi hasil deteksi dalam bentuk *bounding box* dan *mask* segmentasi secara bersamaan. *Bounding box* berfungsi untuk menunjukkan lokasi objek bangunan yang berhasil dikenali oleh model, sedangkan mask segmentasi merepresentasikan bentuk objek secara lebih detail hingga tingkat piksel. Dengan

menampilkan kedua elemen tersebut, evaluasi tidak hanya terbatas pada ketepatan bentuk, tetapi juga mencakup akurasi posisi dan cakupan area objek.

Melalui visualisasi ini, beberapa aspek dapat dianalisis secara langsung. Pertama, ketepatan penempatan *bounding box* terhadap area bangunan yang sebenarnya. Kedua, kesesuaian kontur *mask* dengan batas atap atau struktur bangunan pada citra drone. Ketiga, kemungkinan kesalahan prediksi seperti objek yang tidak terdeteksi, prediksi ganda pada satu bangunan, atau tumpang tindih antar objek yang berdekatan. Pengamatan ini memberikan gambaran kualitatif mengenai perilaku model dalam kondisi visual yang beragam.

Gambar 28 menampilkan contoh hasil visualisasi *bounding box* dan *mask* segmentasi pada data uji. Melalui ilustrasi tersebut, dapat diamati bagaimana model mengidentifikasi lokasi bangunan sekaligus memetakan batas segmentasinya pada citra drone.

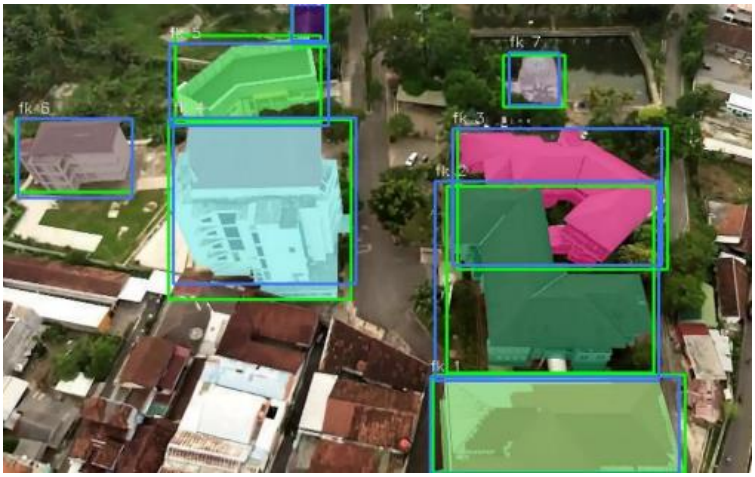

Gambar 28. Visualisasi *bounding box box prediction* dan *ground truth bounding box*.

Berdasarkan Gambar 28, tingkat kesesuaian antara prediksi model dan anotasi *ground truth* dapat diamati dari luas area yang saling bertumpang tindih. Untuk mengukurnya secara kuantitatif, digunakan metrik IoU, yaitu rasio antara luas area irisan (*intersection*) dan luas gabungan (*union*) dari dua area yang dibandingkan.

Pada ilustrasi tersebut, komponen yang digunakan dalam perhitungan IoU adalah sebagai berikut:

- A (hijau) = *bounding box prediction* yang dihasilkan oleh model.
- B (biru) = *ground truth bounding box* dari hasil segmentasi manual.
- *Intersection* = area tumpang tindih antara A dan B.

Berdasarkan ilustrasi pada Gambar 28, berikut contoh perhitungan IoU pada gedung FK 4. Diperoleh data sebagai berikut:

- Luas *bounding box* (A) = 27.966 px²
- Luas *bounding box* (B) = 28.973 px²
- Luas area irisan (A ∩ B) = 27.921 px²

Maka perhitungan IoU adalah sebagai berikut:

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

$$IoU = \frac{|27.921|}{|27.966 + 28.973 - 27.921|} \tag{2}$$

$$IoU = \frac{|27.921|}{|29.018|}$$

$$IoU = 0{,}962$$

Nilai IoU sebesar 0,962 menunjukkan bahwa hampir seluruh area prediksi beririsan dengan area *ground truth*. Dengan kata lain, batas objek yang dihasilkan model sangat mendekati batas sebenarnya pada *instance* tersebut.

Contoh perhitungan ini memberikan gambaran bagaimana IoU merepresentasikan tingkat presisi segmentasi pada satu objek. Namun untuk memperoleh gambaran yang lebih menyeluruh, evaluasi tidak berhenti pada satu instance saja. Analisis selanjutnya dilakukan dengan menghitung rata-rata nilai IoU pada setiap kelas bangunan, mencakup kelompok FK, FKIP, dan FMIPA. Nilai rata-rata tersebut digunakan untuk melihat konsistensi performa segmentasi model pada masing-masing kategori. Hasil perhitungan rata-rata IoU per kelas kemudian divisualisasikan dalam bentuk grafik agar perbandingan antar kelas dapat diamati dengan lebih jelas. Distribusi nilai tersebut ditampilkan pada Gambar 29.

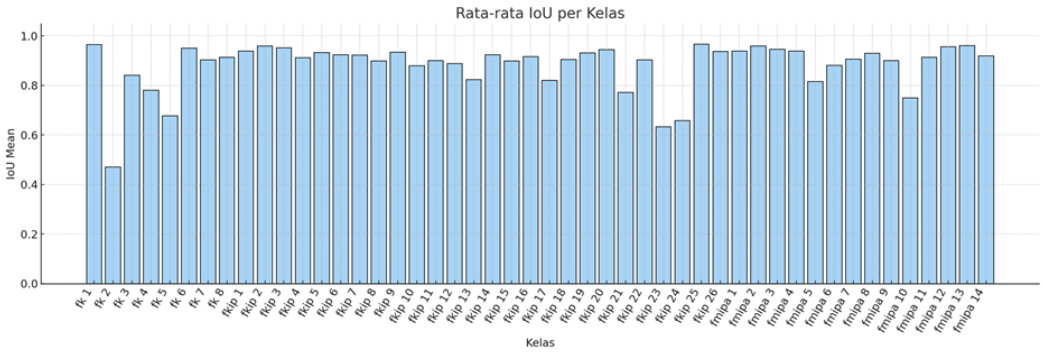

Gambar 29. Grafik rata-rata nilai IoU per-kelas.

Berdasarkan Gambar 29, sebagian besar kelas bangunan menunjukkan nilai rata-rata IoU yang berada pada kategori tinggi. Mayoritas kelas memiliki nilai di atas 0,85, dengan rata-rata keseluruhan mencapai 88,12%. Angka ini menunjukkan bahwa pada sebagian besar label, *mask* prediksi yang dihasilkan model memiliki tingkat tumpang tindih yang kuat dengan *ground truth*. Beberapa kelas bahkan mencatat nilai yang sangat tinggi, mendekati 0,95 hingga 0,97, seperti FKIP 25 (96,63%), FK 1 (96,46%), FMIPA 13 (96,08%), FMIPA 2 (95,96%), FKIP 2 (95,88%), dan FMIPA 12 (95,57%). Pada kelas-kelas tersebut, batas segmentasi yang dihasilkan model hampir sepenuhnya mengikuti kontur bangunan yang sebenarnya.

Disisi lain, grafik juga memperlihatkan adanya variasi antar kelas. Beberapa kelas memiliki nilai IoU yang relatif lebih rendah, seperti FKIP 23 (63,31%) dan FK 2 (47,09%). Perbedaan ini menunjukkan bahwa tingkat kesulitan segmentasi tidak seragam pada setiap kategori. Bangunan dengan ukuran lebih kecil, bentuk yang kompleks, atau kondisi visual yang terganggu oleh bayangan dan vegetasi cenderung menghasilkan nilai IoU yang lebih rendah. Variasi ini menggambarkan bahwa performa model dipengaruhi oleh karakteristik visual masing-masing kelas.

Secara distribusi, nilai IoU yang dominan berada pada rentang tinggi, dengan hanya sebagian kecil kelas yang menunjukkan penurunan signifikan. Pola ini menunjukkan bahwa model mampu mempertahankan kualitas segmentasi yang konsisten pada sebagian besar kategori bangunan, meskipun masih terdapat beberapa kelas yang memerlukan perhatian lebih dalam hal presisi batas objek.

4.6.2. Evaluasi Hasil AP dan mAP

Setelah menganalisis kesesuaian area segmentasi melalui nilai IoU, evaluasi dilanjutkan dengan menggunakan *metrik Average Precision* (AP) dan *mean Average Precision* (mAP). Jika IoU menggambarkan tingkat tumpang tindih pada satu objek secara individual, maka AP dan mAP memberikan gambaran performa yang lebih komprehensif karena mempertimbangkan *confidence score* dari setiap prediksi serta menghitung akurasi pada berbagai ambang IoU.

Metrik AP mengevaluasi hubungan antara *precision* dan *recall* untuk setiap kelas, sehingga tidak hanya menilai besar *overlap*, tetapi juga konsistensi model dalam menghasilkan prediksi yang benar tanpa meningkatkan jumlah deteksi yang salah. Sementara itu, mAP merupakan rata-rata nilai AP pada seluruh kelas, sehingga mencerminkan performa model secara keseluruhan.

Evaluasi pada bagian ini diawali dengan analisis nilai AP50, yaitu Average Precision pada ambang IoU 0,50. Ambang ini umumnya digunakan sebagai standar dasar dalam menilai keberhasilan deteksi dan segmentasi objek karena memberikan toleransi overlap yang moderat. Dengan menggunakan AP50, dapat diamati sejauh mana model mampu mendeteksi dan mensegmentasi bangunan secara konsisten pada tingkat evaluasi awal.

Distribusi nilai AP50 untuk masing-masing kelas bangunan ditampilkan pada Gambar 30. Grafik tersebut memperlihatkan variasi performa antar kategori ketika ambang IoU 0,50 digunakan sebagai batas penilaian.

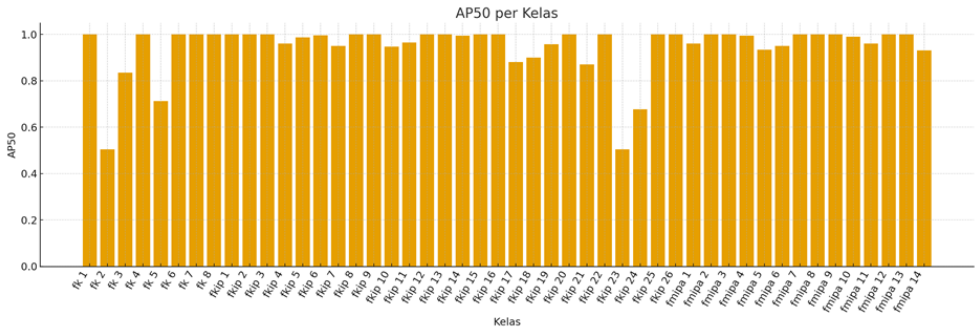

Gambar 30. Hasil evaluasi AP50 per-kelas.

Berdasarkan Gambar 30, pada ambang IoU 0,50 sebagian besar kelas bangunan menunjukkan nilai AP50 yang berada pada kategori tinggi. Mayoritas nilai berada di atas 90%, yang menunjukkan bahwa prediksi model telah memenuhi kriteria overlap minimum untuk dikategorikan sebagai deteksi yang benar. Distribusi ini mengindikasikan bahwa pada tingkat evaluasi dasar, model mampu mengenali dan mensegmentasi bangunan secara konsisten pada hampir seluruh kategori.

Beberapa kelas bahkan mencatat nilai yang sangat mendekati 100%, seperti FK 4, FKIP 13, FKIP 15, dan FMIPA 10. Nilai yang hampir sempurna pada ambang 0,50 menunjukkan bahwa pada kelas-kelas tersebut, sebagian besar objek berhasil terdeteksi dengan tingkat kesalahan yang sangat rendah. Artinya, baik dari sisi lokasi maupun bentuk segmentasi secara umum, model sudah cukup stabil ketika menggunakan toleransi *overlap* yang longgar.

Namun masih terdapat beberapa kelas yang menunjukkan nilai lebih rendah dibandingkan mayoritas kategori, seperti FKIP 23 dan FKIP 24. Meskipun masih berada dalam rentang yang cukup baik, perbedaan ini menunjukkan adanya variasi tingkat kesulitan antar kelas. Faktor seperti bentuk bangunan yang tidak seragam, ukuran objek yang lebih kecil, atau gangguan visual pada citra dapat memengaruhi presisi model pada kategori tertentu.

Secara keseluruhan, rata-rata AP50 sebesar 94,52% memperlihatkan bahwa kemampuan deteksi dan segmentasi model tergolong kuat pada ambang IoU 0,50. Namun, untuk menilai ketelitian batas segmentasi secara lebih ketat, evaluasi perlu dilanjutkan pada ambang IoU yang lebih tinggi. Oleh karena itu, analisis berikutnya menggunakan AP75, yang menuntut tingkat kesesuaian *overlap* yang lebih presisi antara prediksi dan *ground truth*. Distribusi nilai AP75 per kelas ditampilkan pada Gambar 31 sebagai tahap lanjutan dalam mengevaluasi kualitas segmentasi model.

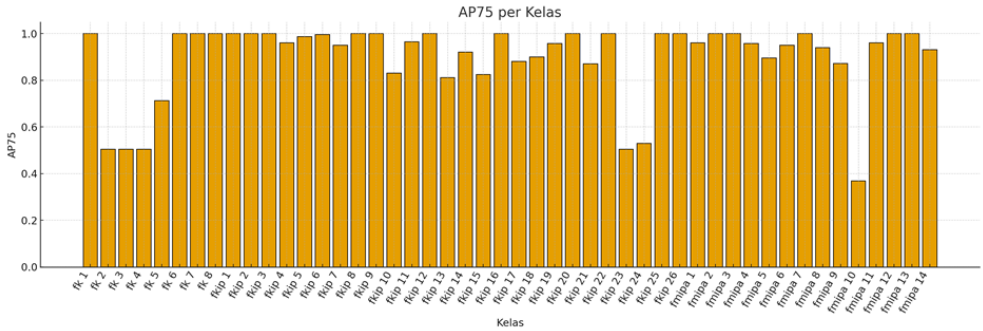

Gambar 31. Hasil evaluasi AP75 per-kelas.

Seperti yang terlihat pada Gambar 31, performa model pada ambang IoU 0,75 menunjukkan pola yang masih konsisten, meskipun lebih ketat dibandingkan evaluasi pada IoU 0,50. Rata-rata AP75 tercatat sebesar 89,50%, sedikit lebih rendah dibandingkan AP50. Penurunan ini dapat dipahami karena pada ambang yang lebih tinggi, perbedaan kecil pada batas segmentasi akan langsung memengaruhi nilai evaluasi. Dengan kata lain, toleransi terhadap ketidaksesuaian area menjadi lebih kecil.

Meskipun terjadi penurunan rata-rata, sebagian besar kelas tetap berada pada kisaran nilai di atas 90%. Hal ini menunjukkan bahwa model mampu mempertahankan ketelitian segmentasi pada banyak kategori meskipun menggunakan standar evaluasi yang lebih ketat. Beberapa kelas seperti FK 1, FMIPA 3, FKIP 9, FKIP 8, dan FKIP 3 bahkan mendekati nilai maksimum, yang menunjukkan bahwa batas segmentasi yang dihasilkan sangat mendekati anotasi *ground truth*.

Tetapi masih terdapat beberapa kelas dengan nilai yang relatif lebih rendah, seperti FKIP 23 dan FMIPA 10, yang berada pada rentang sekitar 35%–55%. Nilai ini menunjukkan bahwa pada kategori tertentu, model masih mengalami kesulitan dalam mengikuti batas objek secara presisi ketika diuji dengan ambang IoU yang tinggi. Variasi antar kelas ini mengindikasikan bahwa karakteristik visual dan kompleksitas bentuk bangunan tetap berpengaruh terhadap performa segmentasi.

Setelah menganalisis performa pada dua ambang IoU yang berbeda, evaluasi dilanjutkan menggunakan metrik mAP untuk memperoleh gambaran yang lebih menyeluruh. Berbeda dengan AP50 dan AP75 yang merepresentasikan satu ambang tertentu, mAP menghitung rata-rata performa pada berbagai tingkat IoU. Dengan demikian, metrik ini memberikan penilaian yang lebih komprehensif terhadap konsistensi model dalam mempertahankan akurasi segmentasi pada berbagai standar evaluasi.

Distribusi nilai mAP untuk masing-masing kelas bangunan ditampilkan pada Gambar 32 sebagai rangkuman performa model secara keseluruhan pada seluruh kategori.

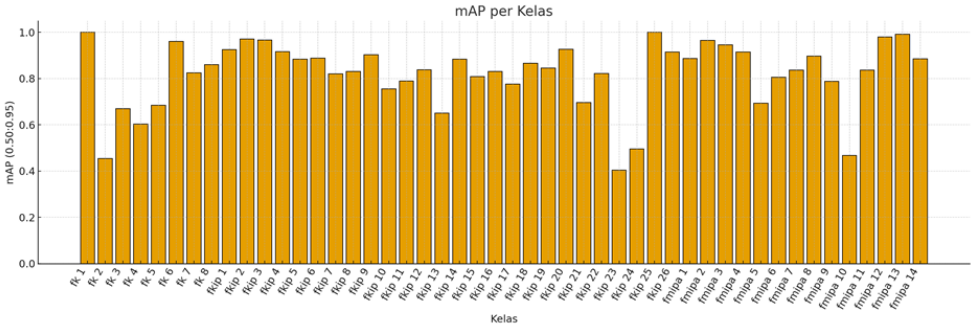

Gambar 32. Hasil evaluasi mAP per-kelas.

Sebagai rangkuman evaluasi pada berbagai ambang IoU, Gambar 32 menampilkan distribusi nilai mAP untuk setiap kelas bangunan. Karena mAP dihitung sebagai rata-rata performa pada beberapa threshold IoU, metrik ini merepresentasikan konsistensi model dalam mempertahankan akurasi segmentasi pada berbagai tingkat evaluasi. Dari grafik terlihat bahwa sebagian besar kelas memiliki nilai di atas 80%, yang menunjukkan bahwa performa model relatif stabil ketika diuji pada standar *overlap* yang berbeda.

Beberapa kelas seperti FKIP 25 dan FK 1 mencapai nilai maksimum, sementara FMIPA 13 dan FMIPA 12 juga berada sangat dekat dengan nilai tertinggi. Nilai yang tinggi dan merata pada berbagai *threshold* menunjukkan bahwa pada kelas-kelas tersebut, model tidak hanya berhasil pada satu ambang IoU tertentu, tetapi mampu menjaga ketelitian segmentasi secara konsisten. Hal ini mencerminkan kualitas prediksi yang baik baik dari sisi lokasi maupun batas objek.

Terdapat juga kelas dengan nilai mAP yang lebih rendah, seperti FKIP 23 dan FMIPA 10, yang berada di bawah 50%. Nilai ini menunjukkan bahwa pada kategori tertentu, performa model cenderung menurun ketika ambang evaluasi semakin ketat. Artinya, meskipun beberapa prediksi mungkin memenuhi kriteria pada IoU yang lebih rendah, konsistensinya berkurang ketika standar kesesuaian diperketat. Variasi ini memperlihatkan bahwa karakteristik visual dan kompleksitas bentuk bangunan tetap memengaruhi kestabilan performa model.

Jika dibandingkan dengan hasil AP50 dan AP75 sebelumnya, nilai mAP memberikan gambaran yang lebih seimbang. AP50 menekankan kemampuan deteksi pada *overlap* minimum, AP75 menilai ketelitian batas segmentasi yang lebih presisi, sedangkan mAP merangkum keduanya dalam satu indikator keseluruhan. Dengan rata-rata yang tetap berada pada kategori tinggi, performa model dapat dikatakan cukup stabil untuk digunakan sebagai dasar dalam tahap berikutnya, yaitu estimasi luas dan analisis bentuk bangunan berdasarkan hasil segmentasi.

4.6.3. Penerapan Faktor Skala ($px^2 \rightarrow m^2$)

Setelah performa model dianalisis dari sisi kualitas segmentasi melalui metrik AP50, AP75, dan mAP, tahap berikutnya adalah mengevaluasi pemanfaatan hasil segmentasi untuk memperkirakan luas bangunan secara kuantitatif. Pada penelitian ini, segmentasi tidak berhenti pada identifikasi bentuk objek, tetapi dilanjutkan pada konversi area mask menjadi estimasi luas dalam satuan meter persegi yang dapat dibandingkan dengan data aktual.

Mask segmentasi yang dihasilkan model merepresentasikan luas objek dalam satuan piksel (px^2). Nilai ini belum dapat langsung diinterpretasikan sebagai luas sebenarnya, karena ukuran piksel dipengaruhi oleh resolusi citra dan ketinggian pengambilan gambar drone. Oleh karena itu, diperlukan faktor skala untuk mengonversi luas dari satuan piksel ke meter persegi (m^2). Proses konversi ini menjadi langkah penting agar hasil segmentasi memiliki makna kuantitatif yang relevan dalam konteks pemetaan bangunan.

Pada penelitian ini, faktor skala diperoleh dengan membandingkan luas hasil anotasi segmentasi (berdasarkan COCO *annotations*) dalam satuan piksel dengan data luas aktual bangunan yang tersedia dalam file CSV *ground truth*. Untuk setiap pasangan citra dan kelas bangunan, dihitung rasio antara luas aktual (m^2) dan luas segmentasi (px^2). Rasio ini merepresentasikan konversi piksel ke meter persegi untuk *instance* tersebut.

Agar nilai skala tidak terlalu dipengaruhi oleh data ekstrem atau *outlier*, rasio yang diperoleh kemudian diagregasikan per kelas menggunakan metode *weighted median*. Pendekatan ini dipilih karena lebih *robust* dibandingkan rata-rata sederhana, terutama ketika terdapat variasi ukuran bangunan yang cukup besar antar *instance*.

Nilai faktor skala yang telah dihitung disimpan dalam bentuk tabel (CSV) serta struktur *dictionary* (JSON), yang memuat skala spesifik per kelas dan satu nilai skala global sebagai cadangan apabila informasi kelas tidak tersedia. Implementasi perhitungan rasio faktor skala dari px² ke m² ditunjukkan pada Kode Program 4.

Kode Program 4. Perhitungan rasio faktor skala (px² → m²) untuk konversi luas bangunan.

```
df_join["ratio_px2m2"] = df_join["area_true_m2"] / df_join["area_px"]

px2m2_per_class = (
df_join.groupby("category_name_lo")["ratio_px2m2"]
.median()
.to_dict()
)

scale_global = df_join["ratio_px2m2"].median()

def convert_px2m2(area_px, class_name):
s = px2m2_per_class.get(class_name, scale_global)
return area_px * s
```

Pada Kode Program 4, proses kalibrasi faktor skala diawali dengan menghitung rasio konversi antara luas aktual bangunan dalam meter persegi (*area_true_m2*) dan luas segmentasi dalam satuan piksel (*area_px*). Rasio ini dihitung untuk setiap pasangan data dan disimpan sebagai kolom baru yang merepresentasikan faktor konversi dasar dari px² ke m² pada level *instance*. Dengan pendekatan ini, setiap bangunan memiliki nilai perbandingan yang menggambarkan hubungan kuantitatif antara luas hasil segmentasi dan luas sebenarnya.

Selanjutnya, nilai rasio tersebut dikelompokkan berdasarkan kelas bangunan. Untuk setiap kelas dihitung nilai median sebagai faktor skala representatif. Pemilihan median bertujuan untuk menjaga stabilitas nilai konversi, terutama ketika terdapat variasi ukuran bangunan atau kemungkinan kesalahan segmentasi yang dapat menghasilkan rasio ekstrem. Dengan menggunakan median, pengaruh *outlier* dapat diminimalkan sehingga faktor skala yang diperoleh lebih *robust*.

Selain faktor skala spesifik per kelas, dihitung pula satu nilai median global dari seluruh rasio yang tersedia. Nilai ini berfungsi sebagai cadangan apabila suatu kelas tidak memiliki jumlah data yang cukup untuk menghasilkan faktor skala yang reliabel. Dengan demikian, sistem konversi tetap dapat berjalan meskipun terdapat keterbatasan data pada kategori tertentu.

Untuk mempermudah implementasi, disediakan fungsi *convert_px2m2()* yang bertugas melakukan konversi luas secara otomatis. Fungsi ini menerima *input* berupa luas dalam piksel dan nama kelas bangunan, kemudian mengambil faktor skala yang sesuai. Jika faktor skala per kelas tidak ditemukan, fungsi akan menggunakan nilai skala global sebagai alternatif. Mekanisme ini memastikan proses konversi berlangsung secara konsisten dan fleksibel sesuai dengan ketersediaan data.

Setelah faktor skala ditetapkan dan fungsi konversi disiapkan, tahap berikutnya adalah menerapkan nilai tersebut pada hasil segmentasi *mask* untuk menghitung estimasi luas bangunan secara langsung. Pada bagian ini dipilih satu frame hasil segmentasi sebagai contoh, di mana luas objek terlebih dahulu dihitung dalam satuan piksel, kemudian dikonversi ke meter persegi menggunakan faktor skala yang telah diperoleh. Visualisasi *frame* segmentasi yang digunakan sebagai contoh perhitungan ditampilkan pada Gambar 33.

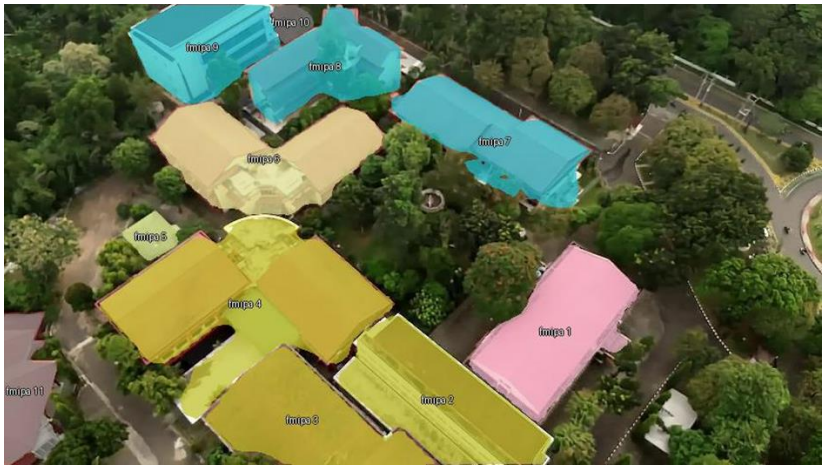

Gambar 33. Hasil segmentasi mask.

Pada Gambar 33 ditampilkan salah satu contoh hasil segmentasi pada kelas FMIPA 1 yang digunakan untuk mengilustrasikan proses konversi luas dari piksel ke meter persegi. Pada contoh tersebut, luas hasil anotasi segmentasi tercatat sebesar 11.770 px², sedangkan luas aktual bangunan berdasarkan data *ground truth* adalah 1.200 m². Untuk menghubungkan kedua nilai tersebut, dihitung rasio antara luas aktual dan luas dalam piksel sebagai faktor skala.

Perhitungan faktor skala dilakukan sebagai berikut:

$$Skala = \frac{Luas\ Aktual\ (m^2)}{Luas\ Anotasi\ (px^2)} = \frac{1.200}{11.770} = 0{,}1019\ m^2/px^2 \tag{1}$$

Nilai 0,1019 m²/px² menunjukkan bahwa setiap satu piksel persegi pada hasil segmentasi merepresentasikan sekitar 0,1019 meter persegi pada kondisi sebenarnya. Dengan faktor ini, luas prediksi model dalam satuan piksel dapat dikonversi secara langsung ke meter persegi.

Sebagai ilustrasi, apabila model menghasilkan luas prediksi sebesar 11.770 px² pada instance yang sama, maka estimasi luas bangunan dihitung sebagai:

$$Luas\ Prediksi\ (m^2) = 11.770 \times 0{,}1019 = 1.200\ m^2$$

Hasil tersebut menunjukkan bahwa proses konversi mampu menghasilkan estimasi yang sangat mendekati nilai aktual pada contoh ini. Meskipun demikian, satu instance tidak cukup untuk merepresentasikan keseluruhan performa estimasi luas. Oleh karena itu, prosedur perhitungan rasio diterapkan pada seluruh pasangan data dalam setiap kelas bangunan. Untuk masing-masing kelas dihitung nilai median dari rasio konversi sebagai faktor skala representatif.

Distribusi nilai faktor skala per kelas kemudian divisualisasikan untuk melihat variasi antar kategori bangunan. Visualisasi tersebut ditampilkan pada Gambar 34 sebagai dasar analisis stabilitas konversi luas pada seluruh dataset.

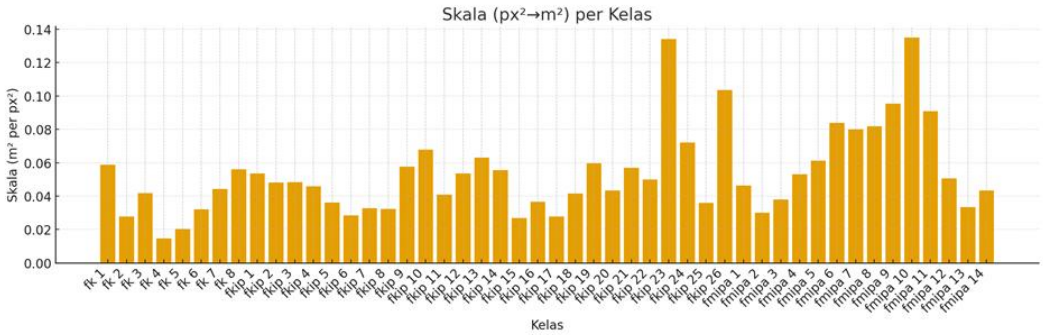

Gambar 34. Distribusi faktor skala (px²→m²) per kelas bangunan.

Berdasarkan Gambar 34, nilai faktor skala (konversi px² ke m²) menunjukkan variasi antar kelas bangunan. Sebagian besar kelas berada pada rentang sekitar 0,03–0,10 m²/px². Rentang ini menunjukkan bahwa hubungan antara luas segmentasi dalam piksel dan luas aktual masih berada dalam pola yang relatif konsisten pada mayoritas kategori.

Namun terdapat beberapa kelas dengan nilai skala yang lebih tinggi, seperti FMIPA 10 (0,1351 m²/px²), FKIP 23 (0,1341 m²/px²), dan FKIP 26 (0,1035 m²/px²). Nilai yang lebih besar mengindikasikan bahwa setiap piksel pada kelas tersebut merepresentasikan luasan meter persegi yang relatif lebih besar dibandingkan kelas lainnya. Kondisi ini dapat terjadi apabila objek pada kelas tersebut memiliki luas aktual yang besar namun tersegmentasi dalam jumlah piksel yang relatif lebih sedikit, sehingga rasio konversinya meningkat.

Sebaliknya, terdapat kelas dengan nilai skala yang relatif kecil, seperti FK 4 (0,0146 m²/px²). Nilai ini menunjukkan bahwa jumlah piksel hasil segmentasi cukup besar dibandingkan luas aktualnya. Hal tersebut dapat dipengaruhi oleh bentuk bangunan yang kompleks, sudut pengambilan gambar, atau adanya area tambahan di sekitar bangunan yang ikut tersegmentasi. Variasi antar kelas ini menggambarkan bahwa karakteristik visual dan ukuran objek memengaruhi rasio konversi dari piksel ke meter persegi.

Meskipun terdapat variasi, penggunaan median rasio per kelas menghasilkan faktor skala yang lebih stabil karena tidak terlalu dipengaruhi oleh nilai ekstrem. Pendekatan ini membantu menjaga konsistensi konversi luas ketika diterapkan pada hasil segmentasi prediksi. Untuk mengantisipasi kondisi ketika data pada suatu kelas terbatas, dihitung pula satu faktor skala global dengan menggabungkan seluruh rasio konversi dari setiap instance tanpa membedakan kategori. Nilai global tersebut dihitung menggunakan median:

$$Sglobal = median(R1, R2, \ldots, Rn)$$

Dari perhitungan diperoleh nilai S_{global} = 0,04822 m^2/px^2, yang setara dengan rasio sekitar 1 m² : 20,74 px². Nilai ini digunakan sebagai faktor konversi cadangan (*fallback*) apabila faktor skala spesifik per kelas tidak tersedia. Dengan adanya faktor skala per kelas dan satu nilai global, proses konversi luas dari hasil segmentasi ke meter persegi dapat dilakukan secara lebih terstruktur dan adaptif sesuai ketersediaan data.

4.6.4. Evaluasi Prediksi Luas Area

Setelah faktor skala diterapkan dan luas hasil segmentasi dikonversi ke satuan meter persegi, tahap selanjutnya adalah mengevaluasi akurasi estimasi luas terhadap data aktual. Pada bagian ini, analisis difokuskan pada selisih antara luas prediksi dan luas *ground truth* untuk menilai ketepatan hasil konversi.

Evaluasi dilakukan menggunakan metrik MAE, MAPE, dan WAPE sebagaimana telah dijelaskan pada Bab II. Ketiga metrik tersebut digunakan untuk mengukur tingkat kesalahan estimasi dalam satuan absolut maupun relatif, sehingga akurasi model dapat dinilai secara kuantitatif dari beberapa sudut pandang.

Sebagai ilustrasi awal, dipilih tiga kelas dengan performa estimasi paling stabil berdasarkan nilai MAE dan MAPE yang rendah, yaitu FKIP 25, FMIPA 2, dan FKIP 4. Pemilihan ini bertujuan untuk memperlihatkan contoh perhitungan pada kelas dengan distribusi data yang cukup representatif dan tingkat kesalahan yang konsisten. Pada kelas-kelas tersebut, selisih antara luas prediksi dan luas aktual relatif kecil baik dalam satuan meter persegi maupun dalam persentase.

Data luas aktual dan hasil prediksi dari ketiga kelas tersebut disajikan pada Tabel 5 sebagai dasar dalam perhitungan nilai MAE, MAPE, dan WAPE pada bagian berikutnya.

Tabel 5. data luas aktual dan prediksi.

Pengujian	**Luas Aktual (Y_t)**	**Luas Prediksi (Y'_t)**
FKIP 25	633,53 m²	637,20 m²
FMIPA 2	316,87 m²	317,52 m²
FKIP 4	468,91 m²	470,72 m²

Untuk mengetahui rata-rata selisih antara luas prediksi dan luas aktual, dilakukan perhitungan MAE menggunakan persamaan (6) yang telah dijelaskan pada Bab II. Perhitungan ini dilakukan dengan membandingkan nilai luas aktual dan luas prediksi pada setiap *instance* bangunan yang diuji.

$$MAE = \frac{1}{3}(|\ 633{,}53 - 637{,}20\ | + |\ 316{,}87 - 317{,}52\ | + |\ 468{,}91 - 470{,}72\ |)$$

$$MAE = \frac{1}{3}(3{,}67 + 0{,}65 + 1{,}81)$$

$$MAE = \frac{1}{3}(6{,}13) = 2{,}04\ m2$$

(6)

Selanjutnya, dilakukan perhitungan MAPE untuk melihat seberapa besar persentase kesalahan hasil prediksi terhadap luas sebenarnya, seperti pada persamaan (7):

$$MAPE = \frac{1}{3}\left(\left|\frac{633{,}53 - 637{,}20}{633{,}53}\right| + \left|\frac{316{,}87 - 317{,}52}{316{,}87}\right| + \left|\frac{468{,}91 - 470{,}72}{468{,}91}\right|\right) \times 100$$

$$MAPE = \frac{1}{3}(0{,}0058 + 0{,}0021 + 0{,}0039) \times 100 = \ 0{,}39\%$$

(7)

Terakhir, dilakukan perhitungan WAPE untuk melihat proporsi kesalahan absolut terhadap rata-rata luas aktual dari seluruh sampel. Nilai ini digunakan untuk menilai konsistensi hasil prediksi secara keseluruhan. Perhitungannya ditunjukkan pada persamaan (8) berikut:

$$WAPE = \frac{MAE}{Rata - Rata\ Luas\ Aktual} \times 100$$

$$WAPE = \frac{2{,}04}{473{,}10} \times 100 = 0{,}43\% \qquad (8)$$

Berdasarkan hasil perhitungan pada tiga kelas contoh, diperoleh nilai MAE sebesar 2,04 m², MAPE sebesar 0,39%, dan WAPE sebesar 0,43%. Nilai tersebut menunjukkan bahwa rata-rata selisih antara luas prediksi dan luas aktual berada pada kisaran yang relatif kecil. Dalam konteks estimasi luas bangunan yang umumnya berada pada ratusan hingga ribuan meter persegi, selisih *absolut* sekitar dua meter persegi dapat dikategorikan sebagai deviasi yang rendah. Demikian pula, persentase kesalahan yang berada di bawah satu persen menunjukkan bahwa perbedaan relatif antara prediksi dan nilai aktual tergolong minimal.

Hasil pada tiga kelas ini digunakan sebagai ilustrasi untuk menunjukkan bagaimana proses evaluasi MAE, MAPE, dan WAPE diterapkan secara rinci. Namun demikian, performa pada beberapa kelas tertentu belum tentu merepresentasikan keseluruhan dataset. Oleh karena itu, evaluasi yang sama kemudian diterapkan pada seluruh data uji untuk memperoleh gambaran performa estimasi luas secara lebih menyeluruh.

Dengan memperluas perhitungan ke seluruh kelas bangunan, dapat diamati distribusi tingkat kesalahan pada kategori dengan performa tinggi maupun pada kategori yang sebelumnya menunjukkan variasi segmentasi yang lebih besar. Ringkasan nilai MAE, MAPE, dan WAPE untuk seluruh kelas disajikan pada Tabel 6 sebagai representasi kinerja model dalam melakukan estimasi luas secara keseluruhan.

Tabel 6. Hasil statistik kesalahan prediksi luas berdasarkan metrik MAE, MAPE, dan WAPE.

Metrik	Minimal	Maksimal	Rata-Rata
MAE (m^2)	2,593	42,315	8,063
MAPE (%)	0,768	24,289	4,205
WAPE (%)	0,665	35,414	3,579

Berdasarkan Tabel 6, performa estimasi luas bangunan dievaluasi melalui metrik MAE, MAPE, dan WAPE pada seluruh kelas data uji. Nilai MAE rata-rata sebesar 8,06 m^2 menunjukkan bahwa secara umum selisih absolut antara luas prediksi dan luas aktual berada dalam rentang yang terkendali. Nilai minimum sebesar 2,59 m^2 menunjukkan adanya kelas dengan deviasi yang sangat kecil, sedangkan nilai maksimum sebesar 42,32 m^2 mengindikasikan bahwa pada beberapa kategori masih terdapat perbedaan yang cukup signifikan. Variasi ini menunjukkan bahwa tingkat akurasi estimasi luas tidak sepenuhnya seragam pada setiap kelas bangunan.

Dari sisi kesalahan relatif, nilai MAPE rata-rata sebesar 4,21% menunjukkan bahwa secara umum penyimpangan prediksi berada pada kisaran empat persen terhadap luas aktual. Rentang nilai antara 0,77% hingga 24,29% memperlihatkan adanya perbedaan performa antar kelas, terutama pada kategori yang sebelumnya juga menunjukkan variasi pada metrik segmentasi. Nilai WAPE rata-rata sebesar 3,58% memperkuat temuan tersebut, dengan total kesalahan prediksi yang berada pada kisaran tiga hingga empat persen dibandingkan total luas aktual keseluruhan dataset.

Secara keseluruhan, hasil ini menunjukkan bahwa model Mask R-CNN mampu menghasilkan estimasi luas bangunan yang cukup akurat dan konsisten berdasarkan hasil segmentasi citra drone. Meskipun masih terdapat beberapa kelas dengan deviasi yang lebih tinggi, rata-rata kesalahan yang relatif kecil menunjukkan bahwa pendekatan segmentasi dan konversi faktor skala yang digunakan dalam penelitian ini sudah berjalan dengan baik dan dapat digunakan sebagai dasar dalam analisis luas bangunan di lingkungan Universitas Lampung.

Secara keseluruhan, hasil ini menunjukkan bahwa proses segmentasi yang dikombinasikan dengan konversi faktor skala mampu menghasilkan estimasi luas dengan tingkat deviasi yang relatif rendah pada mayoritas kelas bangunan. Meskipun masih terdapat beberapa kategori dengan nilai *error* yang lebih tinggi, distribusi rata-rata kesalahan yang tetap berada pada kisaran satu digit persentase menunjukkan bahwa pendekatan yang digunakan cukup stabil untuk merepresentasikan luas bangunan berdasarkan citra drone. Temuan ini menjadi dasar untuk menarik simpulan mengenai kemampuan model dalam melakukan segmentasi sekaligus estimasi luas secara kuantitatif.

4.7. Analisis Hasil

Pada bagian ini disajikan sintesis dari seluruh hasil evaluasi model Mask R-CNN, yang mencakup dua komponen utama: kualitas segmentasi dan akurasi estimasi luas bangunan. Kedua aspek tersebut dianalisis secara terpadu untuk menilai sejauh mana model tidak hanya mampu memisahkan objek bangunan dari latar belakang, tetapi juga menghasilkan estimasi luas yang konsisten setelah proses konversi skala diterapkan.

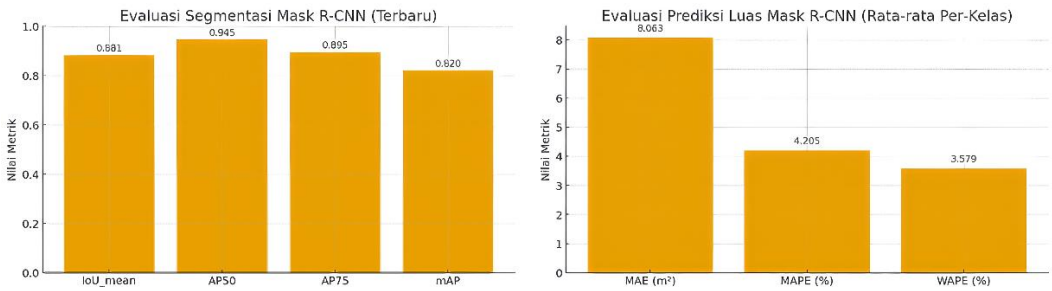

Gambar 35. Grafik hasil evaluasi kinerja model Mask R-CNN.

Pada Gambar 35 menampilkan rangkuman metrik utama yang diperoleh pada data uji. Dari sisi segmentasi, nilai mean IoU sebesar 0,881 menunjukkan tingkat tumpang tindih yang tinggi antara *mask* prediksi dan *ground truth*. Nilai AP50 sebesar 0,945 mengindikasikan bahwa sebagian besar objek berhasil terdeteksi dengan baik pada ambang IoU 0,50, sedangkan AP75 sebesar 0,895 menunjukkan bahwa presisi batas segmentasi tetap terjaga ketika standar evaluasi diperketat. Nilai mAP sebesar 0,820 memperlihatkan bahwa performa model relatif stabil pada berbagai *threshold* IoU, sehingga kualitas segmentasi tidak bergantung pada satu ambang tertentu saja.

Dari sisi estimasi luas, nilai MAE rata-rata sebesar 8,063 m^2 menunjukkan bahwa deviasi absolut antara luas prediksi dan luas aktual berada dalam rentang yang terkendali. Jika dibandingkan dengan skala luas bangunan yang mencapai ratusan hingga ribuan meter persegi, selisih tersebut tergolong proporsional. Nilai MAPE sebesar 4,205% dan WAPE sebesar 3,579% menunjukkan bahwa kesalahan relatif model berada pada kisaran satu digit persentase, sehingga konversi dari px^2 ke m^2 melalui faktor skala dapat dikatakan cukup konsisten pada sebagian besar kelas.

Secara keseluruhan, total luas aktual pada data uji sebesar 17.121,71 m^2 dibandingkan dengan total luas prediksi sebesar 17.242,03 m^2 menghasilkan selisih sekitar 120,32 m^2. Perbedaan ini berada di bawah satu persen dari total luas keseluruhan, sehingga tidak terlihat kecenderungan bias yang dominan, baik dalam bentuk *overestimation* maupun *underestimation*.

Jika kedua aspek dianalisis secara bersamaan, terlihat bahwa kualitas segmentasi yang tinggi selaras dengan tingkat kesalahan estimasi luas yang relatif rendah. Hal ini menunjukkan bahwa *mask* yang dihasilkan model cukup representatif untuk digunakan sebagai dasar perhitungan luas bangunan. Dengan demikian, pendekatan Mask R-CNN yang dikombinasikan dengan kalibrasi faktor skala px^2 ke m^2 mampu memberikan hasil segmentasi yang presisi sekaligus estimasi luas yang konsisten pada citra drone di Universitas Lampung.

V. SIMPULAN DAN SARAN

5.1 Simpulan

Berdasarkan penelitian yang telah dilakukan mengenai implementasi Mask R-CNN dalam analisis rancangan pembangunan gedung, perencanaan tata kelola lahan, dan pemetaan area pada fakultas di Universitas Lampung melalui deteksi segmentasi objek serta prediksi luas bangunan dari citra drone, dapat disimpulkan hal-hal berikut:

1. Model Mask R-CNN dengan backbone ResNet-50 FPN digunakan untuk mendeteksi dan men-segmentasi bangunan pada citra drone di lingkungan Universitas Lampung. Dataset dikonversi dalam format COCO, yang berisi anotasi *bounding box* dan *mask polygon* untuk setiap objek bangunan. Melalui algoritma *Region Proposal Network* (RPN), model dapat mengenali area bangunan secara presisi hingga tingkat piksel. Hasil segmentasi kemudian dikonversi menjadi luas area (m^2) yang dihitung dari rasio antara luas anotasi dan luas aktual di lapangan. Kinerja model dievaluasi menggunakan metrik mAP, AP50, dan AP75 untuk menilai akurasi deteksi dan segmentasi, serta MAE, MAPE, dan WAPE untuk mengukur ketepatan estimasi luas area.

2. Berdasarkan hasil pengujian terbaru, model Mask R-CNN dengan *backbone* ResNet-50 FPN menunjukkan kinerja yang baik dalam mendeteksi dan men-segmentasi bangunan pada citra drone di lingkungan Universitas Lampung. Model mencapai mAP sebesar 82,03%, AP50 sebesar 94,52%, dan AP75 sebesar 89,50%, dengan IoU_mean sebesar 88,12%. Nilai-nilai tersebut menunjukkan segmentasi yang akurat dan konsisten pada sebagian besar kelas bangunan; AP50 yang tinggi menegaskan kemampuan model mengenali objek pada variasi bentuk dan ukuran, sementara AP75 dan mAP merefleksikan ketelitian segmentasi pada tingkat tumpang-tindih yang lebih ketat. Pada tahap estimasi luas area, model memperoleh MAE rata-rata 8,063m^2, MAPE 4,205%, dan WAPE 3,579%, yang berarti kesalahan prediksi luas relatif kecil

terhadap nilai aktual. Secara keseluruhan, metode Mask R-CNN mampu mendeteksi serta men-segmentasi objek bangunan dengan akurat, sekaligus memberikan estimasi luas area yang stabil dan presisi dari citra drone.

Secara keseluruhan, hasil penelitian menunjukkan bahwa metode Mask R-CNN dengan backbone ResNet-50 FPN mampu bekerja dengan baik dalam mendeteksi dan men-segmentasi objek bangunan pada citra drone di lingkungan Universitas Lampung. Model ini tidak hanya mampu menghasilkan segmentasi yang akurat, tetapi juga dapat memberikan estimasi luas area bangunan dengan tingkat kesalahan yang relatif kecil. Kinerja tersebut memperlihatkan bahwa pendekatan berbasis *deep learning* dapat dimanfaatkan secara efektif untuk mendukung proses pemetaan dan analisis tata ruang kampus. Meskipun masih terdapat variasi akurasi antar kelas yang dipengaruhi oleh kondisi citra dan objek bangunan yang terhalang pepohonan, hasil ini menegaskan potensi penggunaan Mask R-CNN sebagai metode yang andal untuk identifikasi serta perhitungan luas objek bangunan dari citra drone.

5.2 Saran

Berikut adalah beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian di masa mendatang, khususnya dalam penerapan Mask R-CNN untuk deteksi, segmentasi, dan prediksi luas area bangunan dari citra drone:

1. Memperluas dataset dengan jumlah citra yang lebih banyak dan variasi kondisi yang lebih beragam, baik dari segi pencahayaan, ketinggian, sudut pengambilan drone, maupun keragaman bentuk dan ukuran bangunan. Hal ini bertujuan untuk meningkatkan kemampuan generalisasi model agar tetap stabil pada berbagai kondisi lapangan.

2. Mengintegrasikan model ke dalam sistem aplikasi praktis, misalnya berbasis *real-time* pada perangkat *mobile* atau terhubung dengan Sistem Informasi Geografis (SIG). Hal ini akan memperluas pemanfaatan hasil penelitian dalam mendukung pemetaan area kampus serta tata kelola lahan yang lebih efektif.

3. Penelitian selanjutnya dapat mencoba menambahkan variasi data melalui teknik augmentasi citra serta melakukan pengolahan gambar yang lebih baik, seperti pengurangan *noise*, agar model lebih stabil dan akurat pada berbagai kondisi citra drone.

4. Menggunakan drone dengan kestabilan terbang yang lebih baik serta kemampuan pengambilan citra beresolusi tinggi, agar hasil perekaman memiliki detail yang lebih tajam. Selain itu, penggunaan drone dengan durasi terbang lebih lama memungkinkan pengambilan data pada area yang lebih luas dan beragam sudut pandang, sehingga dapat memperkaya variasi dataset dan meningkatkan akurasi hasil segmentasi.

5. Membandingkan Mask R-CNN dengan model *deep learning* terbaru, seperti YOLOv8-Seg, *Segment Anything Model* (SAM), atau kombinasi metode *hybrid*. Perbandingan ini dapat memberikan gambaran komprehensif mengenai model yang paling optimal untuk tugas segmentasi dan estimasi luas area pada konteks pemetaan kampus.

DAFTAR PUSTAKA

Aqdi, A. H. H. (2023). *Sistem pendeteksi dan penghitung polen hidup dan mati pada tanaman kelapa sawit menggunakan algoritma YOLO V5 berbasis artificial intelligence* [Skripsi, Universitas Lampung]. Universitas Lampung, Bandar Lampung.

Ardian, R. B., Zakaria, A., & Susilo, G. E. (2016). Study system drainase di Fakultas Teknik Universitas Lampung. *Jurnal Rekayasa Sipil dan Desain, 4*(4), 503–512.

Ariya, C., & Lina, L. (2023). Perancangan deteksi objek pada rak toko menggunakan metode Mask R-CNN. *Simtek: Jurnal Sistem Informasi dan Teknik Komputer, 8*(2), 295–299. https://doi.org/10.51876/simtek.v8i2.213

Ayudhawara, A., & Satrio, B. (2023). Deteksi ketersediaan tempat parkir menggunakan Mask R-CNN (Studi kasus: Fakultas Teknologi Industri Universitas Islam Sultan Agung). *Seminar Riset Mahasiswa-Computer & Electrical (SERIMA-CE), 1*, 245–251.

Bagaskara, R., & Khairunnisa Rizkita, A. (2022). Pendeteksian jumlah bangunan berbasis citra menggunakan metode deep learning. *Jurnal Sains Komputer & Informatika (J-SAKTI), 6*(1), 94–100.

BJ, B. J., Nugroho, K. T., & Saifullah, D. F. N. M. (2023). Pengaruh jumlah epoch dan step per epoch terhadap performa Mask-RCNN pada deteksi objek tanda tangan. *Journal of Electrical, Electronic, Mechanical, Informatic and Social Applied Science, 2*(1), 7–16. https://doi.org/10.58991/eemisas.v2i1.20

Budi, R., Harianto, R. A., & Setyati, E. (2023). Segmentasi citra area tumpukan sampah dengan memanfaatkan Mask R-CNN. *Journal of Intelligent System and Computation, 5*(1), 58–64. https://doi.org/10.52985/insyst.v5i1.305

Chen, J., Wang, G., & Cheng, Z. (2021). Building area estimation in drone aerial images based on Mask R-CNN. *IEEE Geoscience and Remote Sensing Letters, 18*(5), 891–894. https://doi.org/10.1109/LGRS.2020.2988326

Darmanto, B. F., Setianingsih, C., & Saputra, R. E. (2023). Deteksi pelanggaran pada bahu jalan tol menggunakan algoritma Cascade R-CNN. *E-Proceeding of Engineering, 10*(3), 4488–4497.

Dewi, T. N. (2024). *Deteksi dan klasifikasi rambu larangan lalu lintas menggunakan metode YOLO V5s di Kota Bandar Lampung* [Skripsi, Universitas Lampung]. Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Lampung.

Diponegoro, M. H., Kusumawardani, S. S., & Hidayah, I. (2021). Tinjauan pustaka sistematis: Implementasi metode deep learning pada prediksi kinerja murid. *Jurnal Nasional Teknik Elektro dan Teknologi Informasi, 10*(2), 131–138. https://doi.org/10.22146/jnteti.v10i2.1417

Emelyanov, S., Biryukov, A., Sorokin, A., & Emelyanova, E. (2024). *Pixels relationship analysis for extracting building footprints*. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, XLVIII-3, 141–148. https://doi.org/10.5194/isprs-archives-XLVIII-3-2024-141-2024

Gemelli, A., Marinai, S., Pisaneschi, L., & Santoni, F. (2024). *Datasets and annotations for layout analysis of scientific articles*. International Journal on Document Analysis and Recognition, 27, 683–705. https://doi.org/10.1007/s10032-024-00461-2

Grandini, M., Bagli, E., & Visani, G. (2020). Metrics for multi-class classification: An overview. *arXiv preprint*. https://arxiv.org/abs/2008.05756

Harun, A. (2020). Implementasi deep learning menggunakan metode You Only Look Once untuk mendeteksi rokok. *Jurnal Ekonomi, 18*(1), 41–49.

He, K., Gkioxari, G., & Girshick, R. (2017). Mask R-CNN. In *Proceedings of the IEEE International Conference on Computer Vision* (pp. 2980–2988). IEEE. https://doi.org/10.1109/ICCV.2017.322

Hou, T., & Li, J. (2024). Application of Mask R-CNN for building detection in UAV remote sensing images. *Heliyon, 10*(5), e38141. https://doi.org/10.1016/j.heliyon.2024.e38141

Ilahiyah, S., & Nilogiri, A. (2018). Implementasi deep learning pada identifikasi jenis tumbuhan berdasarkan citra daun menggunakan convolutional neural network. *JUSTINDO: Jurnal Sistem dan Teknologi Informasi Indonesia, 3*(1), 49–56.

Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning. *Electronic Markets, 31*, 685–695. https://doi.org/10.1007/s12525-021-00475-2

JIFTI, M. S. M. (2023). Perancangan UFO drone sebagai media pengindraan citra udara di kampus AKN Pacitan. *Jurnal Ilmiah Teknologi Informasi dan Robotika, 2*(1). https://doi.org/10.33005/jifti.v2i1.116

Kassim, Y. M., Byrne, M. E., & Palaniappan, K. (2020). Small object bird detection in infrared drone videos using Mask R-CNN deep learning. In *IS&T International Symposium on Electronic Imaging Science and Technology*. Society for Imaging Science and Technology. https://doi.org/10.2352/ISSN.2470-1173.2020.8.IMAWM-085

Li, Y., Xu, W., & Li, X. (2021). A novel framework based on Mask R-CNN and histogram thresholding for scalable segmentation of new and old rural buildings. *Remote Sensing, 13*(6), 1070. https://doi.org/10.3390/rs13061070

Marpaung, F., Aulia, F., & Nabila, R. C. (2022). Computer vision dan pengolahan citra digital.

Nawawi, H. E., Rahmadewi, R., & Nurpulaela, L. (2024). Pendeteksian wajah hasil dari manipulasi AI pada citra digital. *Jurnal Ilmiah Wahana Pendidikan, 10*(2), 402–409.

Nirmalasari, D. A. (2020). *Pengenalan teks tulisan tangan menggunakan fully convolutional neural network (FCN)* [Skripsi, Institut Teknologi Sepuluh Nopember]. Departemen Teknik Informatika, ITS, Surabaya.

Padilla, R., Netto, S. L., & da Silva, E. A. B. (2021). *A comparative analysis of object detection metrics with a companion open-source toolkit*. arXiv. https://doi.org/10.48550/arXiv.2006.07777

Powers, D. M. W. (2020). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. *arXiv preprint*. https://arxiv.org/abs/2010.16061

Prastowo, E. Y. (2021). Pengenalan jenis kayu berdasarkan citra makroskopik menggunakan metode convolutional neural network. *Jurnal Teknik Informatika dan Sistem Informasi, 7*(2). https://doi.org/10.28932/jutisi.v7i2.3706

Pratiwi, H. A., Cahyanti, M., & Lamsani, M. (2021). Implementasi deep learning flower scanner menggunakan metode convolutional neural network. *Sebatik, 25*(1), 124–130. https://doi.org/10.46984/sebatik.v25i1.1297

Pratomo, A. H., Kaswidjanti, W., & Mu'arifah, S. (2020). Implementasi algoritma region of interest (ROI) untuk meningkatkan performa algoritma deteksi dan klasifikasi kendaraan. *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK), 7*(2), 155–162. https://doi.org/10.25126/jtiik.202071718

Putra, R. R., & Antony, F. (2018). Sistem computer vision pengenalan pola angka dan operator matematika pada permainan kartu angka berbasis jaringan syaraf tiruan perceptron. *Jurnal Ilmiah Informatika Global, 9*(1). https://doi.org/10.36982/jiig.v9i1.441

Rampersad, H. (2020). Developing. In *Total Performance Scorecard* (pp. 159–183). Routledge. https://doi.org/10.4324/9780080519340-12

Raup, A., Ridwan, W., & Zaqiah, Q. Y. (2022). Deep learning dan penerapannya dalam pembelajaran. *JIIP: Jurnal Ilmiah Ilmu Pendidikan, 5*(9), 3258–3267. https://doi.org/10.54371/jiip.v5i9.805

Rosebrock, A. (2016, November 7). Intersection over union (IoU) for object detection. *PyImageSearch*. https://www.pyimagesearch.com/2016/11/07/intersection-overunion-iou-for-object-detection/

Saihu, E. U. K., Purba, A., & Sarkowi, M. (2023). Pemanfaatan teknologi drone guna pemetaan kesesuaian ruang untuk perencanaan lingkungan perumahan di perkotaan. *Jurnal Profesi Insinyur Universitas Lampung, 4*(1), 13–18. https://doi.org/10.23960/jpi.v4n1.92

Shi, W., van de Zedde, R., & Kootstra, G. (2019). Plant-part segmentation using deep learning and multi-view vision. *Biosystems Engineering, 187*, 81–95. https://doi.org/10.1016/j.biosystemseng.2019.08.014

Tammina, S. (2019). Transfer learning using VGG-16 with deep convolutional neural network for classifying images. *International Journal of Scientific and Research Publications (IJSRP), 9*(10), 9420. https://doi.org/10.29322/ijsrp.9.10.2019.p9420

Wardhani, I. P., & Madenda, S. (2016). Algoritma ekstraksi video frame berdasarkan analisis histogram warna HCL. *Jurnal Ilmiah KOMPUTASI, 15*(1), 77–84.

Wang, W., Shi, Y., & Liu, F. (2023). Traditional village building extraction based on improved Mask R-CNN: A case study of Beijing, China. *Remote Sensing, 15*(10), 2616. https://doi.org/10.3390/rs15102616

Wang, Y., Li, S., & Cai, H. (2022). Improved Mask R-CNN for rural building roof type recognition from UAV high-resolution images: A case study in Hunan Province, China. *Remote Sensing, 14*(2), 265. https://doi.org/10.3390/rs14020265

Wulan Dari, S., & Triloka, J. (2022). Kajian algoritme Mask R-CNN dan You Only Look Once (YOLO) untuk deteksi penyakit kulit akibat infeksi jamur. *Seminar Nasional Hasil Penelitian dan Pengabdian Masyarakat*, 132–138.

Zhong, D., He, L., & Lin, Y. (2023). An improved Mask R-CNN: Extraction of door and window instances on village building façade images. *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences, X-1/W1*, 295–301. https://doi.org/10.5194/isprs-annals-X-1-W1-2023-295-2023